

國立交通大學

資訊管理與財務金融學系

財務金融碩士班

碩士論文

分析死亡率模型在評價 GLWB 公平保費的風險

Analyzing the Risks of Mortality Models on
Evaluating Fair Insurance Fees of GLWBs

研究生：徐健勳

指導教授：戴天時 博士

李漢星 博士

中華民國一百零三年六月

分析死亡率模型在評價 GLWB 公平保費的風險

Analyzing the Risks of Mortality Models on
Evaluating Fair Insurance Fees of GLWBs

研 究 生：徐健勳

Student：Chien-Hsun Hsu

指導教授：戴天時

Advisor：Dr. Tian-Shry Dai

李漢星

Dr. Han-Hsing Lee

國立交通大學

財務金融研究所

碩士論文

A Thesis

Graduate Program of Finance, Department of Information Management
and Finance

National Chiao Tung University

in partial Fulfillment of the Requirements
for the Degree of
Master
in
Finance

June 2014

Hsinchu, Taiwan, Republic of China

中華民國一百零三年六月

分析死亡率模型在評價 GLWB 公平保費的風險

學生：徐健勳

指導教授：戴天時 博士

李漢星 博士

摘要

醫療系統的改善使得死亡率減少，也造成人口高齡化的現象，為了確保退休後的生活水平，各種退休基金與相關生存年金商品的發行在金融保險市場扮演了十分重要的角色。為了更精確的替這些商品訂價，可以透過更複雜的死亡率模型得到死亡率與長壽風險，本文研究不同的 Lee-Carter 模型與 CBD 模型，並分析這些死亡率模型的變化對評價保證終身提領保險附約（Guaranteed Lifelong Withdrawal Benefit；GLWB）的公平保費有何影響。本文使用 JP-Morgan 提供的參數校正程式來估計 1950~2004 年的美國死亡率資料，並使用時間序列分析來預測年代效應（period-effect）與世代效應（cohort-effect）的序列參數，透過 Bayesian Information Criterion（BIC）去檢測這些模型的配適程度，再將這些資料去預測 2005~2010 年的死亡率，且使用 Mean Absolute Percentage Error（MAPE）衡量預測結果是否精確。在真實世界下測量的死亡率透過 Wang Transform 轉換在風險中立測度下，再與張國培（2012）提出的 GLWB 定價程式結合，以得到 GLWB 的公平保費率。本文也分析這些死亡率模型或其他市場變數如何影響公平保費率。

關鍵字：保證終身給付提領附約、Lee-Carter、CBD、年代效應、世代效應、公平保費率

Analyzing the Risks of Mortality Models on Evaluating Fair Insurance Fees of GLWBs

Student : Chien-Hsun Hsu

Advisor : Dr. Tian-Shry Dai

Dr. Han-Hsing Lee

National Chiao Tung University

Abstract

Population aging phenomenon becomes more significant due to decrements of mortality rates caused by the improvements of healthcare systems. To ensure the living standard of retiree, various pension funds and related survival annuity products are issued and these products are playing more significant roles in financial and insurance markets. Complex mortality models are developed to capture the mortality and longevity risks in order to accurate price these products. This thesis studies the variations of Lee-Carter mortality model and the CBD model and analyzes how variations of mortality models influence the evaluation of the fair insurance fees of Guaranteed Lifelong Withdrawal Benefits (GLWB). We use the parameter-calibration program provided by JP Morgen to make these mortality models fit 1950~2004 mortality data of USA. Time series analyses are used to predict the series for modeling period-effects and cohort-effects. We use Bayesian Information Criterion (BIC) to measure how these models fit real mortality data. Then we use these models to predict 2005~2010 mortality rates and measure their performance by mean absolute percentage error (MAPE). The mortality rates under the real-world measure are transferred in the rates under the risk-neutral measure. These transferred rates are incorporated into Chang (2012) GLWB pricing model in order to price the fair insurance fees. Sensitivity analyses are given to analyze how mortality models or other market variables influence fair insurance fees.

Keywords: GLWB、Lee-Carter、CBD、period-effects、cohort-effects、Fair Charge

致 謝

之所以能夠完成這篇論文，全都要感謝戴老師，從題目的擬訂到最後的完稿，老師都不辭辛勞地指導著我，在跟戴老師討論的時候，戴老師的專業知識總讓我覺得自己的渺小，但也是特過這樣的討論，讓我在每次討論後都會有新的啟發，才能讓我能夠快速地完成論文，促使自己在二年間進步許多，也希望往後有機會能夠繼續跟戴老師學習。中央財金的楊曉文老師提供許多保險相關知識，讓我們能夠在研究上能夠做的更迅速，更有意義。若沒有戴老師及楊老師的幫忙，我可能就沒辦法如完成該篇論文，真的很謝謝兩位老師。

戴老師的財工研究室成員來自不同的學習背景，有資工、財金、數學等，透過團體 meeting 的方式讓大家能夠學習到不同領域的專業，若有不擅長的問題也可以互相討論，每週的 meeting 讓我學習要如何去詮釋及表達。也感謝楊老師的博班學生對於該篇論文的幫助，以及相關知識的教導。

也感謝交大財金所 01 級的各位，讓我在碩士生涯過得非常開心，留下許多美好回憶，也謝謝所上老師的教導，讓我學到許多專業知識，希望日後能夠有所成就回饋大家，謝謝。

徐健勳 謹誌

國立交通大學財資訊與財務金融學系財務金融碩士班

中華民國一〇三年六月

目錄

中文摘要	I
英文摘要	II
致謝	III
目錄	IV
表目錄	VI
圖目錄	VII
第一章 緒論	1
1.1 研究動機與目的	1
1.2 研究內容	2
1.3 GLWB 簡介	3
第二章 死亡率模型與文獻回顧	5
2.1 死亡率簡介	5
2.2 資料	7
2.3 死亡率模型	8
2.4 文獻回顧	12
第三章 研究方法與步驟	17
3.1 參數估計	17
3.2 參數預測	23

3.3 GLWB 之公平保費率	27
第四章 實證結果分析.....	28
4.1 死亡率模型比較	28
4.2 不同投保年齡的公平保費率分析	31
4.3 不同遞延期的公平保費率分析	37
4.4 不同風險調整因子的公平保費率分析	39
4.5 是否提前解約的公平保費率分析	43
4.6 不同提領比率的公平保費率分析	45
4.7 GMWB 下的公平保費率	48
第五章 結論與未來展望.....	50
5.1 結論	50
5.2 未來展望	51
參考文獻	52

表目錄

Table 1 死亡率模型	8
Table 2 死亡率模型比較結果	29
Table 3 死亡率模型比較結果	30
Table 4 不同投保年齡之公平保費率	31
Table 5 不同投保年齡之誤差	32
Table 6 不同遞延期之公平保費率	37
Table 7 不同遞延期之誤差	38
Table 8 不同風險調整子的公平保費率	39
Table 9 不同風險調整因子之誤差	40
Table 10 是否提前解約與公平保費率	43
Table 11 是否提前解約之誤差	44
Table 12 不同提領比率的公平保費率	45
Table 13 公平保費率的變化量	46
Table 14 不同提領比率之誤差	47
Table 15 不同年齡下 GMWB 的公平保費率	48
Table 16 各模型保費和 Realized 保費率之誤差	49

圖目錄

Fig. 1 中央死亡率 $m_{x,t}$ 表格	7
Fig. 2 60-105 歲的期望存活率	33
Fig. 3 65-105 歲的期望存活率	34
Fig. 4 70-105 歲的期望存活率	35
Fig. 5 75-105 歲的期望存活率	35
Fig. 6 80-105 歲的期望存活率	36
Fig. 7 λ 與期望存活率之關係	40
Fig. 8 $\lambda = -0.25$ 的存活率	41
Fig. 9 $\lambda = -0.15$ 的存活率	42
Fig. 10 $\lambda = -0.05$ 的存活率	42

第一章 緒論

1.1 研究動機與目的

二十世紀以來，因衛生醫療等因素的進步，死亡率隨之下降，使得平均壽命也大幅延長。但隨之而來的是人口高齡化問題，為避免高齡化衝擊政府的政策與預算規劃，以及個人退休生活的安排，人口高齡化的研究在各國相當受到重視，包含未來老年人的死亡率與老年生活的保障等議題。因此，結合投資與保險雙重概念的投資型保單，與計算各年齡層死亡率的 Lee-Carter 模型（Lee and Carter, 1992）、CBD 模型（Cairns, Black and Down, 2006）也隨之出現。

人口老化及壽命延長，除了增加工作人口的負擔，也使得人們擔心退休生活保障不足，而具有投資與保險的保證終身提領保險附約（Guaranteed Lifelong Withdrawal Benefit；GLWB）便因應而生，但由於長壽風險造成壽險公司在設計此商品上有諸多不確定性。壽險公司在設計保險商品時，若無法從眾多的死亡率模型中找出適合該國人口的模型，可能導致錯估死亡率，進而影響商品價格，影響該保險公司之營運。因此，找出適當的死亡率模型是保險公司風險管理的重要課題，本論文研究將不同的死亡率模型套入保險商品 GLWB 的評價模型後對保費的價格影響幅度。

1.2 研究內容

實務上對隨機死亡率模型已有相當程度的發展，本論文採用 JP Morgan 撰寫的程式¹，該程式分別建構 Lee-Carter 模型與其兩個擴充型，以及 CBD 模型與其三個擴充型，另外，本文使用 Human Mortality Database (HMD)² 網站所提供的美國死亡率資料為實證研究部分，從 1950 至 2004 年的資料做參數校正，並用校正好的模型預測 2005 至 2010 年的死亡率，再比較哪個模型在估計與預測上的結果較好，接著將校準死亡率模型參數的結果帶入張國培（2012）保證終身提領保險附約（GLWB）的評價程式，分析不同死亡率模型對保險費率評價結果的影響。

本研究內容涵蓋五章，各章節之重點如下述：

第一章緒論，主要說明研究動機與目的以及內容，並簡單介紹保證終身提領保險附約（GLWB）。

第二章，除了文獻回顧及死亡率模型介紹外，也將簡介中央死亡率（Death Rate）、死亡力（Mortality Force）以及死亡率（Mortality Rate）的定義及數學關係。

第三章為研究方法與步驟，包含死亡率模型參數的估計、死亡率的預測以及 GLWB 的評價。

第四章，實證研究將 HMD 提供的美國死亡人口資料套入不同死亡率模型，找出適合美國資料的模型，也比較將不同死亡率模型套入

¹ 該程式由 JPMorgan 提供，網址 <http://www.lifemetrics.com>

² Human Mortality Database： <http://www.mortality.org>

GLWB 的評價模型分析其對保費的影響。

第五章為結論與建議，除了提出研究的結論外，也對後續的研究發展提出建議。


1.3 GLWB 簡介

GLWB 主要分成遞延期與提領期，最初的遞延期無法提領帳戶價值，這段期間主要將帳戶金額作投資以累積帳戶價值。累積方式有三種，分別為保本機制（Break Even），即遞延到期時可以選擇遞延期末的帳戶價值與所繳總保費的較大值當成最低的保證帳戶價值；複利增值（Roll-up），即遞延到期時可以選擇遞延期末的帳戶價值與遞延期間繳交的保費以約定複利到遞延期末的價值二者取大者當成最低的保證帳戶價值；鎖高機制（Ratchet），以遞延期間帳戶價值曾達到過的最高價值與遞延期末的帳戶價值二者取大者，當成遞延期末的最低保證帳戶價值。在遞延期末時，視當時投保人的年齡決定每期之提領比率。進入提領期後投保人每期可領取一筆固事先約定好的 GLWB 報酬，保戶也可以改變提領金額，如選擇全額提領（提領比率 100%），投保人可領取全額帳戶價值（也就是提前解約），但提領超過固定金額的部分，須扣除一些比例（懲罰比率）當成違約金。若在合約有效期間內投保人死亡，投保人可領回下一個時間點的帳戶價值作為死亡保險金。在提領期時，帳戶價值仍會在市場上進行投資，因此帳戶價值會有高低波動，一旦帳戶價值歸零後，保險公司不會再投入資金進行投資，對投保人而言未來就只剩每期固定報酬可領取。

由於 GLWB 的保費率（ α ）多寡會影響到投保戶未來收取到的

GLWB 報酬，進而影響到報酬的現值。因此，當報酬的現值等於期初所繳的資金時，稱此保費率 (α) 為公平保費率 (Fair Charge)。

不同於領到投保人死亡的 GLWB，具有提領到期日的保證最低提領保險附約 (Guaranteed Minimum Withdrawal Benefit ; GMWB) 也是另一種選擇，而 GMWB 與 GLWB 之差別除了 GMWB 具有提領到期日之外，其提領比率是按照提領期數去計算。



第二章 死亡率模型與文獻回顧

2.1 死亡率簡介

本節將定義何謂中央死亡率、死亡力以及死亡率，並探討其數學之關係。

2.1.1 名詞定義

中央死亡率 $m(x, t)$ ：

$$m(x, t) = \frac{\text{在}t\text{年當年，}x\text{歲的死亡人口}}{\text{在}t\text{年當年，}x\text{歲的平均生存人口}}$$

死亡力 $\mu(x, t)$ ：

$\mu(x, t)$ 解釋為一個人在 x 歲且時間為 t 年的瞬間死亡率，對於一小段時間 dt ，該人在時間 t 到 $t+dt$ 之間的死亡率近似為 $\mu(x, t) \times dt$ 。

死亡率 ${}_rq(x, t)$ ：

${}_rq(x, t)$ 表示某人恰好在 t 年為 x 歲，該人在 t 年到 $t+r$ 年間死亡的機率， $q(x, t)$ 表示該人在 t 年到 $t+1$ 年死亡的機率。

存活率 ${}_rp(x, t)$ ：

${}_rp(x, t)$ 表示某人恰好在 t 年為 x 歲，該人會存活到 $t+r$ 年的機率， $p(x, t)$ 表示該人在 t 年到 $t+1$ 年存活的機率。其中 $p(x, t) = 1 - q(x, t)$ 。

2.1.2 $m(x, t)$ 與 $q(x, t)$ 的關係

在定義上， $m(x, t)$ 與 $q(x, t)$ 的值非常的相似，但根據 Cairns et al. (2009)³提出的假設，可以將它們之間的關係更精確的公式化。

假設：

死亡力 $\mu(x, t)$ 在同一歲數與同一年之間都維持不變，換言之，對於整數 t 和 x 以及所有 $0 \leq s, u \leq 1$ ， $\mu(x + s, t + u) = \mu(x, t)$ 。

在上述假設下， $m(x, t)$ 、 $q(x, t)$ 與 $\mu(x, t)$ 有下列關係：

(a) $m(x, t) = \mu(x, t)$

(b) $q(x, t) = 1 - \exp[-\mu(x, t)] = 1 - \exp[-m(x, t)]$

³ A quantitative comparison of stochastic mortality models using data form England & Wales and United States. *North American Actuarial Journal*, Volume 13, Issue 1, 2009 : 1-35

2.2 資料

2.2.1 死亡率的資料型式




Fig. 1 中央死亡率 $m(x, t)$ 表格

死亡率資料多以橫軸為時間軸，縱軸為年齡軸，如 Fig. 1 所

示。一般而言，高齡人口的死亡率較高，且衛生醫療的進步也使死亡率降低，因此影響死亡率的因素多以年齡（age-effect， $x \in [x_1, x_n]$ ）與年代（period-effect， $t \in [t_1, t_k]$ ）為主。另外，對於不同出生年代的人們，也會影響到死亡率，稱為世代效應（cohort-effect， $t - x \in [t_1 - x_n, t_k - x_1]$ ）。其中， $t \in [t_1, t_k]$ 為估計死亡率參數所需的歷史資料範圍，而 $t \in [t_{k+1}, t_{k+h}]$ 為預測死亡率預測區間。

2.2.2 美國資料

本文使用 HMD 網站所提供的西元 1950-2010 年且 40-105 歲的美國死亡率資料，假定最多活至 105 歲。為了評估各模型的預測精準度，因此將 1950-2004 年的資料做為歷史資料範圍，而 2005-2010 年的資料為判斷各死亡率模型預測精準度的依據。

2.3 死亡率模型

Model	Formula
M1	$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)}\kappa_t + \varepsilon(x, t)$
M2	$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)}\kappa_t + \beta_x^{(3)}\gamma_{t-x} + \varepsilon(x, t)$
M3	$\log(m(x, t)) = \beta_x^{(1)} + \kappa_t + \gamma_{t-x} + \varepsilon(x, t)$
M4	$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \varepsilon(x, t)$
M5	$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x} + \varepsilon(x, t)$
M6	$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \kappa_t^{(3)}((x - \bar{x})^2 - \hat{\sigma}_x^2) + \gamma_{t-x} + \varepsilon(x, t)$
M7	$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x}(x_c - x) + \varepsilon(x, t)$

其中 $\text{logit}(q(x, t)) = \log\left(\frac{q(x, t)}{1 - q(x, t)}\right)$

Table 1 死亡率模型

本篇論文將死亡率模型依序編號為 $M1$ ， $M2$ 等，如 Table 1 所示。而死亡率模型也遵從下列設定：

- 參數 $\beta_x^{(i)}$ 代表與年齡相關的效應。
- 參數 $\kappa_t^{(i)}$ 代表與年代相關的效應。
- 參數 $\gamma_c^{(i)}$ 代表與世代相關的效應，其中 $c=t-x$ 。
- 參數 $\varepsilon(x, t)$ 代表模型的殘差。

死亡率模型簡介如下。

2.3.1 Model M1

Lee 與 Carter (1992) 發表的死亡率模型如下：

$$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)} \kappa_t + \varepsilon(x, t)$$

但 Lee-Carter 模型在估計上會有參數不唯一的問題，舉例如下：

$$\log(m(x, t)) = \tilde{\beta}_x^{(1)} + \tilde{\beta}_x^{(2)} \tilde{\kappa}_t + \varepsilon(x, t)$$

$$\text{where } \tilde{\beta}_x^{(1)} = \beta_x^{(1)} + b\beta_x^{(2)}$$

$$\tilde{\beta}_x^{(2)} = \frac{\beta_x^{(2)}}{a}$$

$$\text{and } \tilde{\kappa}_t = a(\kappa_t - b)$$

對於一組解 $(\beta_x^{(1)}, \beta_x^{(2)}, \kappa_t)$ 可透過上述式子得到另一組解

$(\tilde{\beta}_x^{(1)}, \tilde{\beta}_x^{(2)}, \tilde{\kappa}_t)$ 。為了規避這問題，在模型中加入以下限制式：

$$\sum_t \kappa_t = 0 \quad \text{and} \quad \sum_x \beta_x^{(2)} = 1$$

這兩個限制式可讓 a 、 b 出現唯一解，使得 $(\beta_x^{(1)}, \beta_x^{(2)}, \kappa_t)$ 也為唯一解，而這限制式對於模型的估計品質或是預測品質並無影響。

2.3.2 Model M2

Renshaw 與 Haberman (2006) 將世代效應納入 Lee-Carter 模型。含 cohort-effect 的死亡率模型，一般稱 Age-Period-Cohort 模型 (APC model)。其模型如下

$$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)} \kappa_t + \beta_x^{(3)} \gamma_{t-x} + \varepsilon(x, t)$$

同樣地，M2 模型與 M1 模型皆有參數不唯一的問題，因此需加入下述限制式：

$$\begin{aligned} \sum_t \kappa_t &= 0 \quad \text{and} \quad \sum_x \beta_x^{(2)} = 1 \\ \sum_{x,t} \gamma_{t-x} &= 0 \quad \text{and} \quad \sum_x \beta_x^{(3)} = 1 \end{aligned}$$

2.3.3 Model M3

Currie (2006) 提出更簡化的 APC 模型。

$$\log(m(x, t)) = \beta_x^{(1)} + \kappa_t + \gamma_{t-x} + \varepsilon(x, t)$$

在不失一般性下，亦加入下述限制式：

$$\sum_t \kappa_t = 0 \quad \text{and} \quad \sum_{x,t} \gamma_{t-x} = 0$$

M2 至 M3 可視為 Lee-Carter 模型的衍生版。

2.3.4 Model M4

Cairns、Blake 與 Down (2006) (CBD) 提出的死亡率模型：

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \varepsilon(x, t)$$

其中 $\bar{x}$ 為年齡 x_1 到 x_n (見 Fig. 1) 的平均值； $(x - \bar{x})$ 表示距離平均年齡愈遠則影響愈大。

CBD 模型並無參數不唯一的問題，因此不需加入限制式。

2.3.5 Model M5

Cairns et al. (2009) 考慮將世代效應納入 CBD 模型：

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x} + \varepsilon(x, t)$$

2.3.6 Model M6

Cairns et al. (2009) 提出某些死亡率資料，以 $\text{logit}(q(x, t))$ 描點繪圖時會有曲線的出現，因此修改 M5 加入二次項，得下列模型：

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \kappa_t^{(3)}((x - \bar{x})^2 - \hat{\sigma}_x^2) + \gamma_{t-x} + \varepsilon(x, t)$$

其中 $\hat{\sigma}_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$

2.3.7 Model M7

Cairns et al. (2007) 根據 M2 模型考慮年齡對於世代的反應程度，因此提出與之類似的 M7 模型

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x}(x_c - x) + \varepsilon(x, t)$$

其中 x_c 為一個透過遞回公式⁴算出來的固定常數，且加入下列限制式，以確保參數唯一。

$$\sum_{x,t} \gamma_{t-x} = 0$$

2.4 文獻回顧

2.4.1 Cairns et al. (2009)

該篇研究討論上述 7 個模型，及其參數最佳估計值的方法，並以英格蘭和威爾斯在 1961 至 2004 年、60-89 歲以及美國 1968-2003 年、60-89 歲的資料做為研究分析。

作者以 Bayesian Information Criterion (BIC)⁵ 為判斷模型參數估計是否恰當的依據，也指出英格蘭和威爾斯的資料使用 M7 模型估計的結果較為精確，而美國資料則以 M2 模型估計為精確，但同

⁴ 參照 (3-2) 式。

⁵ 該篇研究對 BIC 的定義如下：

$$BIC = l(\hat{\phi}) - \frac{1}{2} \nu \log N$$

$\hat{\phi}$ 表示最大似估計值； $l(\hat{\phi})$ 表示最大似機率取 $\log$ ； N 為資料個數； ν 是參數個數。

換言之，BIC 越大表示其模型參數估計較為精確且無參數過度配適 (Overfitting) 的問題

時 M2 模型估計美國資料時也有 over-fitting 的問題。

2.4.2 Lee, Wang and Huang, 2012⁶

使用風險中立評價法時，無法直接將真實世界下的死亡率帶入評價模型，而須使用風險中立測度下的死亡率，因此本文使用 Wang-Transform 將真實世界下的死亡率轉換為風險中立機率下的死亡率。

$$\begin{aligned} \text{Wang-Transform } {}_r q^Q(x, t) &= \Phi[\Phi^{-1}({}_r q(x, t)) + \lambda] \\ \Rightarrow {}_r p^Q(x, t) &= 1 - \Phi[\Phi^{-1}(1 - {}_r p(x, t)) + \lambda] \end{aligned}$$

其中上標 Q 表示風險中立機率；無上標代表真實世界的機率； λ 為 market price of risk。本文對於 λ 的設定參考自 Wang and Yang, 2012⁷

做風險中立機率轉換時除討論死亡率的風險，也必須死亡率的隨機變化（例如：考慮時間序列參數變動）的風險，而需使用下列多維的 Wang-Transform 處理多維的 market price of risk。

$$F^Q(g_1, \dots, g_v) = \Phi\left(\Phi^{-1}(F_1(g_1)) - \sum_{j=1}^v \lambda_j g_{1,j}, \dots, \Phi^{-1}(F_v(g_v)) - \sum_{j=1}^v \lambda_j g_{v,j}\right)$$

但本文目前僅考慮死亡率的單一轉換，暫不考慮含有時間序列參數變動風險的多維轉換。

⁶ On the valuation of reverse mortgages with regular tenure payments.

Mathematics and Economics, Volume 51, Issue 2, 2012 : 430-441

⁷ Pricing Survivor Derivatives With Cohort Mortality Dependence Under The Lee-Carter Framework.

The Journal of Risk, Volume 80, Issue 4, 2013 : 1027-1056

2.4.3 Renshaw and Haberman, 2006⁸

該研究除了將 cohort-effect 納入 Lee-Carter 模型外，也提出藉由 ARIMA⁹模型預測時間序列 κ_t 和 γ_{t-x} ，再透過 Lee-Carter 模型的延伸版 M2 預測死亡率，其預測方式如下：

$$\dot{m}(x, t_{k+h}) = m(x, t_k) F(x, t_{k+h})$$

其中 $\dot{m}(x, t_{k+h})$ 為預測死亡率； $m(x, t_k)$ 為 t_k 年且 x 歲的歷史資料；

$F(x, t_{k+h})$ 為預測函數，以 M2 為例其函數如下：

$$F(x, t_{k+h}) = \exp \left[\hat{\beta}_x^{(2)} (\dot{\kappa}_{t_{k+h}} - \hat{\kappa}_{t_k}) + \hat{\beta}_x^{(3)} (\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) \right]$$

$\dot{\kappa}_{t_{k+h}}$ 和 $\dot{\gamma}_{t_{k+h}-x}$ 分別透過 ARIMA 模型預測所得的 period-effect 與 cohort-effect。上標 $\wedge$ 與上標 $\cdot$ 分別代表參數估計值與參數預測值。

2.4.4 張國培, 2012¹⁰

GLWB 的公平保費會受利率期限結構、市場價格風險、死亡率風險與長壽風險而影響，因此難以對其進行評價與避險。在過去的文獻中¹¹，大部分未考慮死亡率的隨機性，而這會大幅影響商品評價

⁸ A cohort-based extension to the Lee-Carter model for mortality reduction factors

Insurance : Mathematics and Economics, Volume38, Issue 3, 2006 : 556-570

⁹ ARMA (p, q) 模型如下：

$$y_t = \omega + \sum_{j=1}^p \varphi_j y_{t-j} + \sum_{j=0}^q \theta_j e_{t-j}$$

ω 、 φ_j 、 θ_j 依序為 drift、AR 參數與 MA 參數；而 $e_t \sim N(0, \sigma^2)$ ， σ^2 由參數校準估出

¹⁰ 在 Hull-White 隨機利率及隨機死亡率下評價保證終身提領給付保險附約

¹¹ Piscopo and Haberman, 2011; Holz et al., 2012; Lin and Tan, 2003; Kijima and Wong, 2007; Peng et al., 2012

的準確性。該篇研究旨在隨機死亡率及隨機利率下找出 GLWB 商品之公平保費率，亦探討分期繳費機制對保費的影響。

該篇研究對於GLWB評價模型的基礎假設如下，商品所連結的標的資產符合幾何布朗運動：

$$dS_t = \mu S_t dt + \sigma_s S_t dZ_t$$

其中：

S_t ：標的資產在時間點 t 的價格

μ ：真實世界下的標的物的期望報酬率

σ_s ：標的資產的波動度

Z_t ：標準布朗運動

假設公平費用率是連續收取，則我們可以將帳戶價值 w_t 表示為：

$$dW_t = (\mu - \alpha)W_t dt + \sigma_s W_t dZ_t$$

$$W_0 = w_0$$

其中 α 即為保險費用率， w_0 為期初繳交資金。

GLWB 於遞延期時每期增資一筆金額到此帳戶，假設增資金額為 C ，因此在遞延期時，每期帳戶價值會上升 C 的高度。而在提領期時，每期投保人可從帳戶提領一筆固定年金，假設年金金額為 G (為遞延期末帳戶價值乘以提領比率(g))，而保戶也可選擇全額提領，則提領超過保證提領金額的部分需乘上懲罰比率(k)當成違約金，即是說保戶可領取 $G + (W_t - G) * (1 - k)$ 。若在合約有效期間，投保人死亡，投保人可領回下一個時間點的帳戶價值作為死亡保險金。

假設死亡率與利率及帳戶價值獨立，可將年金型商品分解成利率及帳戶價值項與存活率項的相乘。如下式：

$$a_x = E \left[\sum_{j=0}^k C_j e^{-\int_0^{T_j} r_u du} {}_{T_j} p_x \right] = \sum_{j=0}^k E \left[C_j e^{-\int_0^{T_j} r_u du} \right] E [{}_{T_j} p_x]$$

其中 a_x 表示一個 x 歲的人購買一個未來第 T_j 年會支付 C_j 元的年金的現值（即 GLWB 的價值）。

有了 GLWB 之價值後，便可計算公平保費率(α)。對於 α 之計算，該篇研究提出利用 Bisection 法來逼近 α 值。當評價結果¹²大於 0，調高保費；當評價結果小於 0，降低保費。直到評價結果趨近於零時，此時的保費則為公平保費。

¹² 此處所指的評價結果為 GLWB 的價值（固定年金的現值） a_x 減去所投資金額在時間 0 的現值

第三章 研究方法與步驟

3.1 參數估計

假定 t 年 x 歲暴露在死亡風險的人數為 $E(x, t)$ 而死亡人數為 $D(x, t)$ ，其中 $t_1 \leq t \leq t_k$ 且 $x_1 \leq x \leq x_n$ 。

本文假設死亡人口服從 Poisson 分配，即 $D(x, t) \sim Po(\Lambda(x, t))$ ，其中 $\Lambda(x, t) = E(x, t) \times m(x, t)$ ，並使用最大概似估計法（Maximum Likelihood Estimation；MLE）估計死亡率模型參數，其最大概似函數為：

$$L(m|D, E) = \sum_{x,t} [D(x, t) \ln(m(x, t)) - E(x, t) \times m(x, t) + \text{Constant}] \quad (3-1)$$

其中 $\text{Constant} = D(x, t) \ln(E(x, t)) - \ln(D(x, t)!)$

該函數推導過程如下：

$$\begin{aligned} \text{Let } l(\Lambda(x, t)|D(x, t)) &= \prod_{x,t} f(D(x, t)|\Lambda(x, t)) \\ &= \prod_{x,t} \frac{\Lambda(x, t)^{D(x, t)} \times e^{-\Lambda(x, t)}}{D(x, t)!} \\ \Rightarrow L(\Lambda(x, t)|D(x, t)) &\equiv \ln l(\Lambda(x, t)|D(x, t)) \\ &= \sum_{x,t} [D(x, t) \ln \Lambda(x, t) - \Lambda(x, t) - \ln[D(x, t)!]] \\ \Rightarrow L(m(x, t)|D(x, t), E(x, t)) &= \sum_{x,t} [D(x, t) \ln[E(x, t) \times m(x, t)] - E(x, t) \times m(x, t) - \ln[D(x, t)!]] \\ &= \sum_{x,t} [D(x, t) \ln[E(x, t)] + D(x, t) \ln[m(x, t)] - E(x, t) \times m(x, t) - \ln[D(x, t)!]] \\ &= \sum_{x,t} [D(x, t) \ln[m(x, t)] - E(x, t) \times m(x, t) + \text{Constant}] \end{aligned}$$

將死亡率模型代入最大概似函數（3-1）式，可求使函數極大化的參數 $m(x, t)$ ，其中 $\varepsilon(x, t)$ 為模型的殘差項，因此在估計參數時，並不考慮該項的存在。

3.1.1 Model M1

$$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)} \kappa_t + \varepsilon(x, t)$$

將 Model M1 代入（3-1）時，不考慮殘差項。

$$L(\beta_x^{(1)}, \beta_x^{(2)}, \kappa_t) = \sum_{x,t} [D(x, t) \times (\beta_x^{(1)} + \beta_x^{(2)} \kappa_t) - E(x, t) \times \exp(\beta_x^{(1)} + \beta_x^{(2)} \kappa_t) + \text{Constant}]$$

由於對數概似函數 $L(\beta_x^{(1)}, \beta_x^{(2)}, \kappa_t)$ 存在雙線性項（Bilinear） $\beta_x^{(2)} \kappa_t$ ，因此無法用一般的方法去得參數的 MLE。因此我們利用遞迴的方式估計含雙線性項的模型參數 θ 如下：

$$\hat{\theta}^{(v+1)} = \hat{\theta}^{(v)} - \frac{\partial L^{(v)} / \partial \theta}{\partial^2 L^{(v)} / \partial \theta^2} \quad (3-2)$$

上標 $(v+1)$ 表示透過上標 (v) 的舊參數所計算出來的參數，直到兩者之差的絕對值小於 10^{-4} 。

透過遞迴公式（3-2），我們可以得到估計參數 $\beta_x^{(1)}, \beta_x^{(2)}, \kappa_t$ 的遞迴式如下：

$$\begin{aligned}
(\hat{\beta}_x^{(1)})^{(v+1)} &= (\hat{\beta}_x^{(1)})^{(v)} - \frac{\sum_t [D(x,t) - \hat{D}^{(v)}(x,t)]}{-\sum_t \hat{D}^{(v)}(x,t)} \\
(\hat{\kappa}_t)^{(v+1)} &= (\hat{\kappa}_t)^{(v)} - \frac{\sum_x [D_{x,t} - \hat{D}^{(v)}(x,t)] (\hat{\beta}_x^{(2)})^{(v)}}{-\sum_x \hat{D}^{(v)}(x,t) \left((\hat{\beta}_x^{(2)})^{(v)} \right)^2} \\
(\hat{\beta}_x^{(2)})^{(v+1)} &= (\hat{\beta}_x^{(2)})^{(v)} - \frac{\sum_t [D_{x,t} - \hat{D}^{(v)}(x,t)] (\hat{\kappa}_t)^{(v)}}{-\sum_t \hat{D}^{(v)}(x,t) \left((\hat{\kappa}_t)^{(v)} \right)^2}
\end{aligned}$$

其中 $\hat{D}(x,t)$ 為用模型死亡率代入所得的死亡人數

並以 $\hat{\kappa}_t$ 為例說明：

$$\begin{aligned}
\frac{\partial L}{\partial \kappa_t} &= \sum_x [D(x,t) \hat{\beta}_x^{(2)} - \hat{\beta}_x^{(2)} E(x,t) \exp(\hat{\beta}_x^{(1)} + \hat{\beta}_x^{(2)} \hat{\kappa}_t)] = \sum_x [D(x,t) - \hat{D}(x,t)] \hat{\beta}_x^{(2)} \\
\frac{\partial^2 L}{\partial \kappa_t^2} &= -\sum_x \left(\hat{\beta}_x^{(2)} \right)^2 [E(x,t) \exp(\hat{\beta}_x^{(1)} + \hat{\beta}_x^{(2)} \hat{\kappa}_t)] = -\sum_x \hat{D}(x,t) \left(\hat{\beta}_x^{(2)} \right)^2 \\
\hat{\kappa}_t^{(v+1)} &= \hat{\kappa}_t^{(v)} - \frac{\sum_x [D(x,t) - \hat{D}^{(v)}(x,t)] (\hat{\beta}_x^{(2)})^{(v)}}{-\sum_x \hat{D}^{(v)}(x,t) \left((\hat{\beta}_x^{(2)})^{(v)} \right)^2}
\end{aligned}$$

3.1.2 Model M2

$$\log(m(x, t)) = \beta_x^{(1)} + \beta_x^{(2)} \kappa_t + \beta_x^{(3)} \gamma_{t-x} + \varepsilon(x, t)$$

將 Model M2 代入 (3-1) 式時，亦有雙線性項的存在，因此仿照 Model M1 之處理辦法，可得估計 M2 模型參數的遞迴式如下：

$$\begin{aligned} (\hat{\beta}_x^{(1)})^{(v+1)} &= (\hat{\beta}_x^{(1)})^{(v)} - \frac{\sum_t [D(x, t) - \hat{D}^{(v)}(x, t)]}{-\sum_t \hat{D}^{(v)}(x, t)} ; (\hat{\gamma}_{t-x})^{(v+1)} = (\hat{\gamma}_{t-x})^{(v)} - \frac{\sum_x [D_{x,t} - \hat{D}^{(v)}(x, t)] (\hat{\beta}_x^{(3)})^{(v)}}{-\sum_x \hat{D}^{(v)}(x, t) (\hat{\beta}_x^{(3)})^{(v)2}} \\ (\hat{\kappa}_t)^{(v+1)} &= (\hat{\kappa}_t)^{(v)} - \frac{\sum_x [D_{x,t} - \hat{D}^{(v)}(x, t)] (\hat{\beta}_x^{(2)})^{(v)}}{-\sum_x \hat{D}^{(v)}(x, t) (\hat{\beta}_x^{(2)})^{(v)2}} ; (\hat{\beta}_x^{(3)})^{(v+1)} = (\hat{\beta}_x^{(3)})^{(v)} - \frac{\sum_t [D_{x,t} - \hat{D}^{(v)}(x, t)] (\hat{\gamma}_{t-x})^{(v)}}{-\sum_t \hat{D}^{(v)}(x, t) (\hat{\gamma}_{t-x})^{(v)2}} \\ (\hat{\beta}_x^{(2)})^{(v+1)} &= (\hat{\beta}_x^{(2)})^{(v)} - \frac{\sum_t [D_{x,t} - \hat{D}^{(v)}(x, t)] (\hat{\kappa}_t)^{(v)}}{-\sum_t \hat{D}^{(v)}(x, t) (\hat{\kappa}_t)^{(v)2}} \end{aligned}$$

3.1.3 Model M3

$$\log(m(x, t)) = \beta_x^{(1)} + \kappa_t + \gamma_{t-x} + \varepsilon(x, t)$$

將 Model M3 代入 (3-1) 式時，雖然不存在雙線性項，但在不失一般性下，我們仍參照前面的估計方式，得其 M3 模型參數的遞迴式如下：

$$\begin{aligned} (\hat{\beta}_x^{(1)})^{(v+1)} &= (\hat{\beta}_x^{(1)})^{(v)} - \frac{\sum_t [D(x, t) - \hat{D}^{(v)}(x, t)]}{-\sum_t \hat{D}^{(v)}(x, t)} ; (\hat{\gamma}_{t-x})^{(v+1)} = (\hat{\gamma}_{t-x})^{(v)} - \frac{\sum_x [D_{x,t} - \hat{D}^{(v)}(x, t)]}{-\sum_x \hat{D}^{(v)}(x, t)} \\ (\hat{\kappa}_t)^{(v+1)} &= (\hat{\kappa}_t)^{(v)} - \frac{\sum_x [D_{x,t} - \hat{D}^{(v)}(x, t)]}{-\sum_x \hat{D}^{(v)}(x, t)} \end{aligned}$$

3.1.4 Model M4

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \varepsilon(x, t)$$

將 Model M4 代入 (3-1) 式，得到下列式子：

$$L(m|D, E) = \sum_{x, t} [D(x, t) \times \ln(\ln(1 + e^{\kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x})})) - E(x, t) \ln(1 + e^{\kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x})}) + \text{Constant}]$$

Note :

$$\begin{aligned} \text{logit}(q(x, t)) &= \log\left(\frac{q(x, t)}{1 - q(x, t)}\right) \\ &= \log\left(\frac{1 - p(x, t)}{p(x, t)}\right) \\ &= \log\left(\frac{1 - e^{-m(x, t)}}{e^{-m(x, t)}}\right) \\ &= \log(e^{m(x, t)} - 1) \\ \Rightarrow m(x, t) &= \log(1 + e^{\text{logit}(q(x, t))}) \end{aligned} \quad (3-3)$$

我們仍就使用遞迴公式的方式去計算該模型參數的遞迴式，以 $\hat{\kappa}_t$ 為例說明：

$$\begin{aligned} \hat{\theta}^{(v+1)} &= \hat{\theta}^{(v)} - \frac{\partial L^{(v)} / \partial \theta}{\partial^2 L^{(v)} / \partial \theta^2} \\ \frac{\partial L}{\partial \kappa_t^{(2)}} &= \sum_x [D(x, t) \times \frac{1}{\ln(1 + e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})})} \times \frac{e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})}}{1 + e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})}} \times (x - \bar{x}) - E(x, t) \times \frac{e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})}}{1 + e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})}} \times (x - \bar{x})] \\ &= \sum_x [D(x, t) \times \frac{1}{\ln(1 + e^{\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x})})} \times \frac{1}{e^{-(\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x}))} + 1} \times (x - \bar{x}) - E(x, t) \times \frac{1}{e^{-(\hat{\kappa}_t^{(1)} + \hat{\kappa}_t^{(2)}(x - \bar{x}))} + 1} \times (x - \bar{x})] \end{aligned}$$

令 $f(\kappa_t^{(2)}) = \frac{\partial L}{\partial \kappa_t^{(2)}}$ ，則 L 對 $\kappa_t^{(2)}$ 的二次微分可用微積分基本定理計

算，如下：

$$\frac{\partial^2 L}{(\partial \kappa_t^{(2)})^2} = \lim_{\Delta \kappa \rightarrow 0} \frac{f(\kappa_t^{(2)} + \Delta \kappa) - f(\kappa_t^{(2)})}{\Delta \kappa}$$

求得 L 對 $\kappa_t^{(2)}$ 的一階與二階微分，並建構遞迴式，利用遞迴式求

Model M4 參數的估計值。

3.1.5 Model M5

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x} + \varepsilon(x, t)$$

Model M5 參照 M4 作法可求其參數估計值的遞迴式。

3.1.6 Model M6

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \kappa_t^{(3)}((x - \bar{x})^2 - \hat{\sigma}_x^2) + \gamma_{t-x} + \varepsilon(x, t)$$

Model M6 參照 M4 作法可求其參數估計值的遞迴式。


3.1.7 Model M7

$$\text{logit}(q(x, t)) = \kappa_t^{(1)} + \kappa_t^{(2)}(x - \bar{x}) + \gamma_{t-x}(x_c - x) + \varepsilon(x, t)$$

Model M7 參照 M4 作法可求其參數估計值的遞迴式。

3.1.8 cohort 參數的估計問題

使用遞迴方法估計 Model M2、M5、M6 以及 M7 時，參數 γ_{t-x} 數列會出現最初四項與末尾四項皆為相同之常數，無法正確反映不同世代的 cohort-effect，如下所示。



0.000156
0.000156
0.000156
0.000156
-50.26503
-54.78243
-58.7678
⋮
97.22179
100.0015
0.000156
0.000156
0.000156
0.000156

因此本文使用 ARIMA 模型來重新估計有問題序列，將該 γ_{t-x} 參數數列扣掉前四項與後四項後，將其餘之數列轉換成定態後使用 ARIMA 模型來預測前四項與後四項的值。

3.2 參數預測

本節將預測時間序列參數 κ_t 與 γ_{t-x} 預測未來年代或世代的效應，並介紹單位根檢驗將非定態數列換成定態（Stationary）¹³數列

¹³ 定態（Stationary）：

時間序列是由一隨機過程產生，若此經由隨機過程所產生的分配與時間獨立的話，亦即此分配不隨時間而改變，則稱此數列為定態的時間序列。

及如何使用 ARMA 模型預測轉換後的定態數列，進而求得 κ_t 與 γ_{t-x} 。

3.2.1 ARMA 模型

ARMA (p, q) 模型如下：

$$y_t = \omega + \sum_{i=1}^p \varphi_i y_{t-i} + \sum_{j=0}^q \theta_j e_{t-j}$$

ω 、 φ_j 、 θ_j 依序為 drift、AR 參數與 MA 參數； y_t 為時間序列參數；而 $e_t \sim N(0, \sigma^2)$ ， σ^2 由參數校準估出。

將時間序列參數 y_t 套入至 ARMA 模型前，必須先確保其為定態，可透過單位根檢驗（Unit Root Test）¹⁴的方式以確保該序列參數為定態，對於非定態的時間序列參數可透過差分的方式來消除單位根得到定態的時間序列參數。

本文所使用的單位根檢測方式為 Augment Dickey-Fuller test（ADF-test），使用 ADF-test 時，令序列參數有單位根為虛無假設（null hypothesis），因此當檢定結果無法拒絕虛無假設時，即表示該數列存有單位根。然而 ADF-test 在本文使用的美國資料中無法完全檢查出所有的非定態（nonstationary process）過程，如 Model M7 的 $\kappa_t^{(1)}$ ，因此本文亦採用 Kwiatkowski-Phillips-Schmidt-Shin test（KPSS test）來處理 ADF-test 所無法檢測出的序列函數，使用 KPSS test 時，令時間序列是定態為虛無假設，因此檢定結果若無法拒絕虛無假設，即該時間序列為定態。

¹⁴單位根檢驗（Unit Root Test）：

檢驗時間序列參數是否為定態，常見的單位根檢驗如：ADF-test、KPSS test。

透過單位根檢驗與差分得到定態時間序列參數，便可將該序列參數代入 ARMA (p, q) 預測。

3.2.2 模型配適

ARMA (p, q) 模型中的 p 、 q 分別決定 AR 參數與 MA 參數的數量，為了避免不適當的 p 、 q 造成參數預測不精確或是過度配適 (overfitting)¹⁵ 的問題，我們使用 BIC 模型找出最適的 p 、 q ，BIC 模型如下：

$$BIC = -2 \ln(\hat{\phi}) + \nu \log N$$

其中， $\hat{\phi}$ 表示最大概似估計值； $l(\hat{\phi})$ 表示最大概似估計值取 $\log$ ； N 為資料個數； ν 是參數個數。換言之，BIC 越小表示其模型參數配適程度較優，因此藉由尋找最小的 BIC 去決定最適的 p 、 q 。

有了最適 p 、 q 後，便可對各模型之時間序列參數做預測，並預測 h 年，再將參數預測值代入各死亡率模型預測未來之死亡率。

3.2.3 死亡率預測

對於死亡率的預測，本文皆以最新一年的歷史資料為預測基底，並往後預測 h 年，各模型的死亡率預測型式如下：

¹⁵ 過度配適 (overfitting)：

相對於可用的資料量來說，若模型使用過多的參數，可能會減少模型的配適能力。

$$\begin{aligned}
 M1 \quad & m(x, t_{k+h}) = m(x, t_k) \times \exp\left(\hat{\beta}_x^{(2)}(\dot{\kappa}_{t_{k+h}} - \hat{\kappa}_k) + \varepsilon(x, t_{k+h})\right) \\
 M2 \quad & m(x, t_{k+h}) = m(x, t_k) \times \exp\left(\hat{\beta}_x^{(2)}(\dot{\kappa}_{t_{k+h}} - \hat{\kappa}_k) + \hat{\beta}_x^{(3)}(\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) + \varepsilon(x, t_{k+h})\right) \\
 M3 \quad & m(x, t_{k+h}) = m(x, t_k) \times \exp\left((\dot{\kappa}_{t_{k+h}} - \hat{\kappa}_k) + (\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) + \varepsilon(x, t_{k+h})\right) \\
 M4 \quad & \text{logit}(q(x, t_{k+h})) = \text{logit}(q(x, t_k)) + (\dot{\kappa}_{t_{k+h}}^{(1)} - \hat{\kappa}_{t_k}^{(1)}) + (x - \bar{x})(\dot{\kappa}_{t_{k+h}}^{(2)} - \hat{\kappa}_{t_k}^{(2)}) \\
 & \quad + \varepsilon(x, t) \\
 M5 \quad & \text{logit}(q(x, t_{k+h})) = \text{logit}(q(x, t_k)) + (\dot{\kappa}_{t_{k+h}}^{(1)} - \hat{\kappa}_{t_k}^{(1)}) + (x - \bar{x})(\dot{\kappa}_{t_{k+h}}^{(2)} - \hat{\kappa}_{t_k}^{(2)}) \\
 & \quad + (\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) + \varepsilon(x, t) \\
 M6 \quad & \text{logit}(q(x, t_{k+h})) = \text{logit}(q(x, t_k)) + (\dot{\kappa}_{t_{k+h}}^{(1)} - \hat{\kappa}_{t_k}^{(1)}) + (x - \bar{x})(\dot{\kappa}_{t_{k+h}}^{(2)} - \hat{\kappa}_{t_k}^{(2)}) \\
 & \quad + ((x - \bar{x})^2 - \hat{\sigma}_x^2)(\dot{\kappa}_{t_{k+h}}^{(3)} - \hat{\kappa}_{t_k}^{(3)}) + (\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) + \varepsilon(x, t) \\
 M7 \quad & \text{logit}(q(x, t_{k+h})) = \text{logit}(q(x, t_k)) + (\dot{\kappa}_{t_{k+h}}^{(1)} - \hat{\kappa}_{t_k}^{(1)}) + (x - \bar{x})(\dot{\kappa}_{t_{k+h}}^{(2)} - \hat{\kappa}_{t_k}^{(2)}) \\
 & \quad + (x_c - x)(\dot{\gamma}_{t_{k+h}-x} - \hat{\gamma}_{t_k-x}) + \varepsilon(x, t)
 \end{aligned}$$

將 M4 至 M7 之結果 $\text{logit}(q(x, t_{k+h}))$ 代入 (3-3) 式，得 $m(x, t_{k+h})$

3.2.4 Wang Transform

由於 GLWB 之評價方式為在風險中立機率的假設下計算，因此無法直接帶入真實世界的預測死亡率。本文透過 Wang Transform 來轉換為風險中立機率下的死亡率。

$${}_r p^Q(x, t) = 1 - \Phi[\Phi^{-1}(1 - {}_r p(x, t)) + \lambda] \quad (3-4)$$

風險中立下的死亡率計算如下：

Step 1：

$${}_r p(x, t) = \exp\left[-\sum_{i=0}^r m(x+i, t+i)\right]$$

Step 2：

將 ${}_r p(x, t)$ 的結果代入 (3-4) 求 ${}_r p^Q(x, t)$

Step 3 :

$$m^Q(x+r, t+r) = -\ln(p^Q(x+r, t+r)) - \sum_{i=0}^{r-1} m^Q(x+i, t+i)$$

其中 $m^Q(x, t)$ 為風險中立機率下的死亡率。

有了風險中立機率下的死亡率後，可透過 Monte Carlo 求出期望死亡率與期望存活率，便能將期望存活率代入 GLWB 的評價模型計算其價值。

3.3 GLWB 之公平保費率

有了 $m^Q(x, t)$ 後，我們便可計算 GLWB 的價值與公平保費率。而一開始我們並不知道公平保費率為多少，因此使用 Bisection 法來逼近公平保費，若 GLWB 的價值扣掉期初所繳資金之值大於 0，調升保費率；反之若小於 0，降低保費率，直至該值趨近於 0，此時的保費便為公平保費率。

第四章 實證結果分析

本章將討論各模型對於 1950-2010 年美國死亡率資料的估計準確度以及預測準確度，並將各死亡率模型的預測結果代入 GLWB 計算公平保費率，比較不同死亡率模型之間公平保費率的差別，亦討論不同投保年齡、不同遞延期與不同 λ 對保費的影響。

GLWB 的假設：帳戶價值累積機制設為保本機制，每年期數 6 期，保費收取區間為遞延期與提領期，超額懲罰比率 0.1，期初投入資金為 100，且帳戶價值服從 LogNormal 分配，一年提領次數為 1，帳戶價值波動度為 0.3，利率服從 Vasieck Model，且平均利率水準為 0.0325，利率波動度為 0.01，利率均數迴歸速度為 0.1，帳戶價值與利率的相關係數為-0.25。

4.1 死亡率模型比較

本文將 1950-2010 年的資料分為 1950-2004 與 2005-2010 兩部分，前者為估計各死亡率模型參數所需的歷史資料，後者為比較死亡率預測結果是否精確的依據。

模型比較的方式主要以 BIC 與 MAPE 兩種，BIC 為分析模型配適程度比較，其公式如下

$$BIC = \ln(\hat{\phi}) - \frac{1}{2} \nu \log N \quad (4-1)$$

其中， $\hat{\phi}$ 表示最大概似估計值； $l(\hat{\phi})$ 表示最大概似估計值取 log； N 為資料個數； ν 是參數個數。換言之，BIC 越大表示其模型參數配適

程度較優。

MAPE 為分析死亡率估計值或死亡率預測值與歷史資料的誤差程度，公式如下：

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{A_i - F_i}{A_i} \right| \times 100\% \quad (4-2)$$

其中， A_i 表示死亡率的實際值； F_i 表示死亡率的估計值或預測值。

4.1.1 分析 40-105 歲

本小節將探討 40-105 歲的死亡率資料對各死亡率模型的影響。

	BIC	MAPE Estimation	MAPE Forecast
Model M1	-33656.9	3.14%	3.67%
Model M2	-26496.3	2.02%	5.06%
Model M3	-33961.3	5.16%	2.47%
Model M4	-71061.4	6.38%	3.45%
Model M5	-51282.9	5.41%	5.53%
Model M6	-44192.4	5.28%	5.05%
Model M7	-47588.8	4.84%	5.38%
History			5.6168%

Table 2 死亡率模型比較結果

MAPE Estimation 與 BIC 為使用 1950-2004 年資料的比較結果，MAPE Forecast 為 2005-2010 年預測值的比較結果。從 Table 2 中的 BIC 與 MAPE Estimation 兩項來看可以發現 Model M2 在估計值的部分明顯優於其他死亡率模型。而在預測值 MAPE Forecast 也可以發

現 M3 反而有較好的預測結果，而原先估計結果較優的 M2，在預測的結果較差。其中 History 為 2004 年各年齡之資料計算 2005-2010 年死亡率之誤差。

4.1.2 分析 60-105 歲

由於 GLWB 的商品多適用於退休族群，而一般退休族群的年齡多為 60 歲以上，因此本節將分析 60-105 歲的死亡率資料。

	BIC	MAPE Estimation	MAPE Forecast
Model M1	-48153.1	3.10%	3.70%
Model M2	-24554	1.79%	3.54%
Model M3	-49554	5.16%	2.15%
Model M4	-85790.1	7.01%	4.33%
Model M5	-41519	6.00%	9.10%
Model M6	-33477.2	3.64%	14.40%
Model M7	-32185.2	3.01%	5.21%
History			6.2325%

Table 3 死亡率模型比較結果

根據 Table 3 我們仍舊得到 Model M2 在估計值的部份較為優異；Model M3 在預測方面為優。從上述兩表格我們可以得知，Lee-Carter 系列的死亡率模型（M1 至 M3）對於美國資料的估計以及預測都大致優於 CBD 系列的死亡率模型（M4 至 M7）。而 Model M2 在模型配適優於其他模型的結果，與 Cairns et al.（2009）發表的研究結果相符合。在 Forecast 上，M3 則較為優秀。其中 History 為

2004 年各年齡之資料計算 2005-2010 年死亡率之誤差。

4.2 不同投保年齡的公平保費率分析

討論不同死亡率模型的預測值與不同投保年齡對於公平保費率的影響。

4.2.1 不同投保年齡的公平保費率

首先探討投保戶在 2005 年投保 GLWB，不同的投保年齡對公平保費率的影響，年齡分別為 60、65、70、75 與 80 歲。除了前述 GLWB 的假設外，本小節將加入遞延期為 10 年、 λ 為 -0.25、提領比率為 0.01 且可提前解約的設定。

Age Model	60	65	70	75	80
M1	2.29889%	1.74957%	1.41037%	1.26326%	1.09726%
M2	2.69440%	2.16843%	1.64761%	1.34445%	1.10687%
M3	2.64753%	1.99677%	1.51886%	1.30051%	1.11443%
M4	2.24945%	1.69464%	1.38702%	1.26068%	1.09039%
M5	1.73447%	1.42548%	1.31802%	1.23013%	1.03752%
M6	1.46393%	1.34308%	1.31269%	1.22978%	0.96405%
M7	2.14096%	1.59027%	1.36505%	1.26617%	1.11992%
History	2.21100%	1.71902%	1.41449%	1.27922%	1.12473%

Table 4 不同投保年齡之公平保費率

Table 4 分析 60-105 歲（共 45 年）、65-105 歲（共 40 年）、...、80-105（共 25 年）歲的公平保費率。我們可以發現到公平費用率隨

投保年齡上升而下降，且下降幅度越來越小，這是因為投保年齡愈高，受保險人的平均生存年限就愈低，所能領取的固定年金也較少，因此高齡投保者的保費率才顯得越來越低。其中，History 模型的數值是將 2010 年各年齡層的資料經過 Wang Transform 轉換並代入 GLWB 評價模型而得的公平保費率。

下表 Table 5 是使用 History 模型為 benchmark 而計算各模型與 History 的誤差。計算方式為該模型的費用率扣掉歷史資料的費用率取絕對值後除上歷史資料的費用率，再轉換為百分比。

Age Model	60	65	70	75	80	平均(MAPE)
M1	3.9752%	1.7775%	0.2913%	1.2480%	2.4420%	1.9468%
M2	21.8634%	26.1434%	16.4806%	5.0993%	1.5873%	14.2348%
M3	19.7438%	16.1574%	7.3786%	1.6640%	0.9157%	9.1719%
M4	1.7391%	1.4180%	1.9417%	1.4493%	3.0525%	1.9201%
M5	21.5528%	17.0761%	6.8204%	3.8379%	7.7534%	11.4081%
M6	33.7888%	21.8694%	7.1966%	3.8647%	14.2857%	16.2011%
M7	3.1677%	7.4895%	3.4951%	1.0199%	0.4273%	3.1199%

Table 5 不同投保年齡之誤差

Table 5 的最右欄（平均）為模型在各年齡之間誤差的平均值（即 MAPE），而紅字部分則代表與 History 模型最近似的模型。從該結果我們發現 Model M4 與 M1 與歷史資料的結果十分近似，M7 次之，其它模型的誤差較大。直接使用 2010 年各死亡率的資料估計未來的死亡率，其實只處理了 age-effect，並未處理 period-effect 與

cohort-effect，所以 M1 和 M4¹⁶的結果會和歷史資料結果接近，而其它模型因為多處理了 cohort-effect，所以算出來的公平保費率和歷史資料的結果相差許多。實驗數據可發現，Lee-Carter 系列的 cohort-effect 會拉高公平保費率，CBD 系列的 cohort-effect 會壓低公平保費率。

4.2.2 期望存活率與公平保費率

本小節探討風險中立下期望存活率與公平保費率之間的關係。




Fig. 2 60-105 歲的期望存活率

從 Fig. 2 可以發現說，Model M2 在投保者存活至 33 年之前，其存活率比 Model M3 小，但活至 33 年後，M2 存活率會比 M3 大許多，整體而言，M2 還是有較高的存活率，對照 Table 4 的 60 歲投保者，可發現 M2 的公平保費率也確實比其他 Model 還大，簡單的

¹⁶ 這兩個模型僅處理 age-effect 與 period-effect。

說，若一個投保者他擁有較高的存活率，則該投保者在未來所能領取的固定年金也比較多，保險公司在不虧損的狀況下必會對該投保者收取較高的保費，因此，M6 的低存活率也導致使用 M6 會產生較低的保費率。

History 的存活率與 M1、M4 與 M7 較為相近，所以產生的公平保費也相近，對應 Table 5 也發現其公平保費誤差很小，而存活率最大的 M2 與最小的 M6 的誤差則大。




Fig. 3 65-105 歲的期望存活率

Fig. 3 可以發現 M1、M4 的存活率十分貼近 History 的存活率，對照 Table 5 的 60 歲與 65 歲投保誤差，亦發現 M1 與 M4 的誤差也減少，值得注意的是 M7 誤差不減反增，初步觀察是因為 Fig. 2 在存活約 29 年之前，M7 有比 History 高的存活率，過了 29 年後 M7 的存活率卻比 History 低，而 M7 與 History 的存活率因為這一高一低的關係，使得他們的整體的保費率誤差較小。但 Fig. 3 的 M7 的期望存活率都低於 History 的存活率，所以 M7 的公平保費率較

History 低甚多。




Fig. 4 70-105 歲的期望存活率

根據 Fig. 4 所示，除了 M5 與 M6 存活率沒甚麼太大變動外，其餘模型的期望存活率都明顯有貼近 History 期望存活率的趨勢，Table 5 在 70 歲各模型的誤差也都比 65 歲小。




Fig. 5 75-105 歲的期望存活率

隨投保年齡增長，各模型的存活率也逐漸接近 History 存活率，如 Fig. 5。




Fig. 6 80-105 歲的期望存活率

從 Fig. 6 來看，各模型的存活率已經十分近似 History，Table 5 也充分驗證此結果。

隨投保年齡增長，存活率也趨近於 History，因此我們可以發現到當投保年齡增加，period-effect 與 cohort-effect 愈來愈不顯著，所以死亡率模型結果才會趨近 History。

4.3 不同遞延期的公平保費率分析

本節將探討不同遞延期對於公平保費率的影響，並將遞延期分為 5 年、10 年、15 年、20 年與 25 年這五種狀況去分析比較。除了 GLWB 前述的設定外，亦加入投保年齡 60 歲、 λ 為 -0.25、提領比率 0.01 且可提前解約的設定。

4.3.1 不同遞延期的公平保費率

Deferred Model	5	10	15	20	25
M1	4.781799%	2.298889%	1.223602%	0.749817%	0.444260%
M2	5.413513%	2.694397%	1.515770%	0.899506%	0.532834%
M3	5.492477%	2.647533%	1.421356%	0.850067%	0.515671%
M4	4.743347%	2.249451%	1.190643%	0.735741%	0.442200%
M5	3.639221%	1.734467%	1.013489%	0.628967%	0.328903%
M6	3.018494%	1.463928%	0.954437%	0.590515%	0.197067%
M7	4.597435%	2.140961%	1.136398%	0.716858%	0.432587%
History	4.597092%	2.210999%	1.190643%	0.730548%	0.431213%

Table 6 不同遞延期之公平保費率

如同 Table 4，History 仍為 2010 年各年齡層的資料經過 Wang Transform 轉換並代入 GLWB 評價模型而得的公平保費率。我們發現到遞延期拉長，公平保費率會下降，而 M2、M3 的保費率偏高與 M6 的偏低，和之前觀測結果符合。

Deferred Model	5	10	15	20	25	平均(MAPE)
M1	4.017923%	3.975159%	2.768167%	2.637608%	3.025477%	3.284867%
M2	17.75952%	21.86336%	27.30681%	23.12754%	23.56626%	22.72470%
M3	19.47722%	19.74379%	19.37716%	16.36022%	19.58599%	18.90888%
M4	3.18148%	1.739133%	0.000000%	0.710803%	2.547771%	1.635837%
M5	20.83645%	21.55279%	14.87889%	13.90472%	23.72611%	18.97979%
M6	34.33906%	33.78882%	19.83852%	19.16818%	54.29936%	32.28679%
M7	0.007468%	3.167700%	4.555940%	1.873935%	0.318471%	1.984703%

Table 7 不同遞延期之誤差

Table 7 計算不同死亡率模型的費率和 History 費率的價差比例，其計算方式如同 Table 5。從上表中我們可以發現 Model M1、M4 與 M7 較為接近 History 模型，和之前的觀察大致相符。

4.4 不同風險調整因子的公平保費分析

4.4.1 不同風險調整因子的公平保費率

本節將討論風險調整因子(λ)的變動，對於公平保費率的影響，使用的 λ 分別為-0.25、-0.15 與-0.05。除了原先的 GLWB 設定外，亦加入投保年齡 60 歲、遞延期 10 年、提領比率 0.01 且可提前解約的設定。

λ Model	-0.25	-0.15	-0.05
M1	2.298889%	2.194519%	2.095642%
M2	2.694397%	2.592688%	2.502136%
M3	2.647533%	2.520676%	2.397766%
M4	2.249451%	2.150574%	2.058563%
M5	1.734467%	1.674728%	1.619110%
M6	1.463928%	1.433029%	1.408997%
M7	2.140961%	2.058563%	1.980286%
History	2.210999%	2.112122%	2.018738%

Table 8 不同風險調整子的公平保費率




Fig. 7 λ 與期望存活率之關係

Fig. 7 是以 Model M1 為例，將不同 λ 下 M1 的風險中立期望存活率以圖表示之，當 λ 愈大其期望存活率愈低。從 Table 8 我們發現說當 λ 愈大，公平保費率愈低；反之 λ 愈小，公平保費率則愈高。

λ Model	-0.25	-0.15	-0.05	平均(MAPE)
M1	3.975159%	3.901167%	3.809524%	3.895283%
M2	21.863357%	22.752762%	23.945576%	22.853898%
M3	19.743790%	19.343304%	18.775509%	19.287534%
M4	1.739133%	1.820544%	1.972787%	1.844155%
M5	21.552792%	20.708713%	19.795919%	20.685808%
M6	33.788820%	32.152145%	30.204081%	32.048349%
M7	3.167700%	2.535763%	1.904764%	2.536076%

Table 9 不同風險調整因子之誤差

Table 9 使用 History 當 benchmark，從 Table 8 與 Table 9，我們

可以發現 Model M4 在不同的 λ 下的保費率較為貼近 History 模型的公平保費率。

4.4.2 期望存活率與公平保費率

本小節將從期望存活率去探討公平保費率及與 History 模型下的公平保費率誤差。




Fig. 8 $\lambda = -0.25$ 的存活率

從 Fig. 8 可以發經過 Wang-Transform 轉換後的 Model M4 與轉換後 History 的存活率較為貼近，因此其公平保費率的誤差也較小，參照 Table 9。而存活率最大的 M2 與最小的 M6 也各自對應到最大與最小的公平保費率，參照 Table 8。




Fig. 9 $\lambda = -0.15$ 的存活率




Fig. 10 $\lambda = -0.05$ 的存活率

Fig. 10 與前面兩圖表的結果類似。從 Fig. 7 至 Fig. 10 來看，可以發現到 λ 對存活率無太大影響，公平保費率則會隨 λ 變大而變小。

4.5 是否提前解約的公平保費率分析

本節探討是否可以提前解約對於公平保費率的影響。除了原先的 GLWB 設定外，亦加入 λ 為-0.25、投保年齡 60 歲遞延期 10 年與提領比率 0.01 的設定。

4.5.1 是否提前解約的公平保費率

是否提前解約 Model	有提前解約	沒有提前解約	Option Premium
M1	2.298889%	1.932221%	0.366669%
M2	2.694397%	2.227478%	0.466919%
M3	2.647533%	2.156067%	0.491467%
M4	2.249451%	1.888962%	0.360489%
M5	1.734467%	1.592674%	0.141792%
M6	1.463928%	1.430969%	0.032959%
M7	2.140961%	1.811371%	0.329590%
History	2.210999%	1.882782%	0.328217%

Table 10 是否提前解約與公平保費率

從 Table 10 可知，提前解約的選擇權提供保險人更多權利，所以保險公司可據此收取較高的保費，有提前解約與沒提前解約費用率價差（標注為 Option Premium）反映提前解選擇權的價值。M1、M4 和 M7 求的 Option Premium 和 History 模型的 Premium 十分接近，其他 Lee-Carter 模型則高估 Option Premium，CBD 模型則低估 Option Premium，因為 Lee-Carter 的 cohort-effect 拉高公平保費，而

CBD 的 cohort-effect 則降低公平保費率，而導致此現象。

使用 History 模型的費用率當 benchmark，其他模型和歷史模型的誤差如 Table 11 所示：

是否提前 Model	有提前解約	沒有提前解約	平均(MAPE)
M1	3.975159%	2.625822%	3.300490%
M2	21.863357%	18.307802%	20.085580%
M3	19.743790%	14.514952%	17.129371%
M4	1.739133%	0.328227%	1.033680%
M5	21.552792%	15.408459%	18.480626%
M6	33.788820%	23.997085%	28.892953%
M7	3.167700%	3.792855%	3.480278%

Table 11 是否提前解約之誤差

根據 Table 11，我們可以發現到整體而言沒有提前解約的保費率與歷史值之誤差小，但平均而言，仍以 Model M4 與歷史值之誤差最小，M1 和 M7 次之，其他較大。

4.6 不同提領比率的公平保費率分析

本節探討不同提領比率對公平保費率的影響，除了 GLWB 原先設定外，亦加入 λ 為-0.25、投保年齡 60 歲、遞延期 10 年與可提前解約的設定。

4.6.1 不同提領比率 (g) 的公平保費率

Model \ g	0.03	0.05	0.07
M1	1.216736%	2.298889%	4.237976%
M2	1.356468%	2.694397%	5.045471%
M3	1.318016%	2.647533%	5.053024%
M4	1.196137%	2.249451%	4.155579%
M5	1.086960%	1.734467%	2.947083%
M6	1.081467%	1.463928%	2.263012%
M7	1.163178%	2.140961%	3.946838%
History	1.196137%	2.210999%	4.029236%

Table 12 不同提領比率的公平保費率

從 Table 12 我們可以發現到，當提領比率愈大，則公平保費率也愈大。投保戶在未來所能領取的 GLWB 報酬變多時，保險公司在不虧本的狀況下，勢必會收取更多的公平保費。根據 Fig. 2，我們可以發現 M6 與 M5 分別有最低與次低的期望存活率，M2 則有最高的期望存活率，而存活率高低也影響到公平保費率的變化量，從下表 Table 13 可以發現愈高的存活率，其公平保費率的變化量也愈高；反之，愈低的存活率則有愈低的公平保費率變化量。雖然提領比率

的增加亦會增加公平保費率，但對於存活率較低的模型來說，能領到報酬的機會也較低，因此公平保費率的增加量與期望存活率的高低成正比。

Model \ g	0.03→0.05	0.05→0.07
M1	1.082153%	1.939087%
M2	1.337929%	2.351074%
M3	1.329517%	2.405491%
M4	1.053314%	1.906128%
M5	0.647507%	1.212616%
M6	0.382462%	0.799084%
M7	0.977783%	1.805878%
History	1.014862%	1.818237%

Table 13 公平保費率的變化量

使用 History 模型的費用率當 benchmark，其他模型和歷史模型的誤差如 Table 14 所示，其中紅字代表與 History 模型接近的模型，其結果和之前的觀察大致相符。

g Model	0.03	0.05	0.07	平均(MAPE)
M1	1.72215%	3.97516%	5.18064%	3.62598%
M2	13.40413%	21.86336%	25.22154%	20.16301%
M3	10.18944%	19.74379%	25.40900%	18.44741%
M4	0.00000%	1.73913%	3.13565%	1.62493%
M5	9.12744%	21.55279%	26.85753%	19.17926%
M6	9.58668%	33.78882%	43.83521%	29.07024%
M7	2.75545%	3.16770%	2.04499%	2.65605%

Table 14 不同提領比率之誤差

4.7 GMWB 下的公平保費率

GMWB 亦是結合投資概念的保險商品，但與 GLWB 不同之處是具有到期日，因此在到期日之前，投資人每期可領取固定報酬，且可隨時執行該附約領回當時的帳戶價值與可提領金額取大者。

本節使用 2005 年到 2010 年的真實資料去計算 $\lambda = -0.05$ 下的公平保費率，並比較不同死亡率模型。

4.7.1 不同投保年齡下 GMWB 的公平保費率

本小節探討不同投保年齡下，GMWB 的公平保費率，而保單規格設定為遞延期 1 年、提領期 5 年、提領比率 20%，其他設定參照 GLWB 之規格。

Age Model	60	65	70	75	80
M1	13.0791%	12.6151%	11.9353%	10.9575%	9.5080%
M2	13.0449%	12.6974%	12.0122%	11.1099%	9.5403%
M3	13.1053%	12.6775%	11.9833%	11.0399%	9.5622%
M4	13.1534%	12.6920%	11.9964%	10.9836%	9.4839%
M5	13.0734%	12.5515%	11.7986%	10.7817%	9.2216%
M6	13.1108%	12.5670%	11.7581%	10.6705%	9.0170%
M7	13.2988%	12.7110%	12.0348%	11.1003%	9.6432%
History	13.0325%	12.5517%	11.8474%	10.8421%	9.3851%
Realized	13.1094%	12.6755%	11.9778%	11.0275%	9.6666%

Table 15 不同年齡下 GMWB 的公平保費率

Age Model	60	65	70	75	80	平均
M1	0.2311%	0.4767%	0.3554%	0.6351%	1.6409%	0.6678%
M2	0.4924%	0.1734%	0.2866%	0.7472%	1.3070%	0.6013%
M3	0.0314%	0.0163%	0.0459%	0.1121%	1.0797%	0.2571%
M4	0.3352%	0.1300%	0.1548%	0.3985%	1.8895%	0.5816%
M5	0.2750%	0.9778%	1.4962%	2.2291%	4.6029%	1.9162%
M6	0.0105%	0.8559%	1.8344%	3.2379%	6.7197%	2.5317%
M7	1.4443%	0.2803%	0.4758%	0.6600%	0.2415%	0.6204%
History	0.5866%	0.9764%	1.0892%	1.6812%	2.9124%	1.4492%

Table 16 各模型保費和 Realized 保費率之誤差

Realized 為使用 2005-2010 年之真實死亡率資料計算所得之保費率，而從 Table 16 我們可以發現到 Model M3 的預測結果與真實死亡率的實際值較為接近，根據 Table 3 也可以發現到 M3 的預測結果較為靠近真實世界下的死亡率資料。History 為使用 2004 年各年齡之資料作為死亡率預測值並計算其保費率，由於 2004 年之資料僅考慮 age-effect，並沒有討論 cohort-effect 與 period-effect，相較於真實死亡率所計算之結果，History 明顯低估公平保費率。

第五章 結論與未來展望

5.1 結論

本研究討論隨機死亡率模型參數的校準及預測，並比較不同的隨機死亡率模型與 GLWB 的公平保費率評價的影響。以下為本篇論文之重點。

從實證結果中可以發現，對於美國資料，Lee-Carter 系列（M1 至 M3）不論在估計（M2）或是預測（M3），都明顯比 CBD 系列（M4 至 M7）的模型來得優異，此結果和 Cairns et al.（2009）的研究結論相同。然而撇開死亡率估計的部份不談，只用 6 年的死亡率資料（2005~2010 年）來比較各死亡率模型預測精確度也未必公允，雖說 Model M3 在預測這 6 年的結果較為優異，但拉至更長年限，M3 未必最優。但公平保費率的部份卻不是如此，若以 2010 年的實際死亡率資料所求得的公平保費率為基準¹⁷來看，M1 和 M4 未考慮 cohort-effect 與 period-effect 則較貼近 History 模型，M7 次之。這可能是因為 M2、M3、M5 至 M7 模型多處理 cohort-effect，而用實際歷史預估則沒有 cohort-effect。

有些保險公司在估計未來死亡率時，往往使用歷史資料當作未來死亡率的估計值，但同時也忽略了 cohort-effect 與 period-effect，導致死亡率低估而造成保險公司虧損，根據 Table 16，我們可以發現到 M3 的公平保費率最接近透過實際資料所得的公平保費率，因

¹⁷ 目前保險公司多半採用歷史死亡率資料來估算保單價值與公平保費。

此我們更加認為保險公司在估算未來死亡率時，應考慮 cohort-effect 與 period-effect，以避免造成公司低估保費率而虧損。

5.2 未來展望

本研究雖然探討死亡率模型風險的問題，但仍有幾點可以使該風險更精確的反應出來。本文目前僅考慮 Wang Transform 的單一轉換，因此若採用多維的轉換，也許能得到較精確的公平保費率結果，或是使用 Chen and Cox¹⁸ Transform。此外，由於美國資料有限，因此無法更精確的比較死亡率模型預測結果，若未來能找到更多年份的資料，也許可以找出更好的死亡率預測模型。而本文的相關研究也可以應用在其他商品，如 reverse mortgage 的訂價。

¹⁸ Modeling Mortality With Jumps : Application To Mortality Securitization.

The Journal of Risk and Insurance. Volume 76, Issue 3, 2009 : 727-751

參考文獻

1. 張國培, (2012) “Pricing Guaranteed Life Withdrawal Benefit under Hull-White Interest Rate Model and Stochastic Mortality Model”. 交通大學財金所碩士論文
2. Cairns, A.J.G., Blake, D., Dowd, K., Coughlan, G.D., Epstein, D., Ong, A., and Balevich, I. (2009) “A quantitative comparison of stochastic mortality models using data from England & Wales and United States.” *North American Actuarial Journal*, Volume 13, Issue 1 : 1-35.
3. Cairns, A.J.G., Blake, D., and Dowd, K. (2006) “A Two-Factor Model For Stochastic Mortality With Parameter Uncertainty : Theory And Calibration”. *The Journal of Risk and Insurance*, Volume 73, Issue 4 : 687-718.
4. Chen, H., and Cox, S.H. (2009) “Modeling Mortality With Jumps : Applications To Mortality Securitization”. *The Journal of Risks and Insurance*, Volume 76, Issue 3 : 727-751
5. Holz, D., A. Kling, and J. Russ. (2012) “GMWB for Life: An Analysis of Lifelong Withdrawal Guarantees”. *Zeitschrift für die gesamte Versicherungswissenschaft*, Volume 101, Issue 3 : 305-325.
6. Kijima, M., and T. Wong. (2007) “Pricing of Ratchet Equity-Indexed Annuities under Stochastic Interest Rates”. *Insurance: Mathematics and Economics*, Volume 41, Issue 3 : 317-338.

7. Lee, Y.-T., Wang, C.-W., and Huang, H.-C. (2012) "On the valuation of reverse mortgages with regular tenure payments". *Mathematics and Economics*, Volume 51, Issue 2 : 430-441.
8. Lee, D., and Carter, L.R.. (1992) "Modeling and Forecasting U.S. Mortality". *Journal of the American Statistical Association*, Volume 87, Issue 419 : 659-671.
9. Peng, J., K.S. Leung, and Y.K. Kwok. (2012) "Pricing Guaranteed Minimum Withdrawal Benefits under Stochastic Interest Rates". *Quantitative Finance*, Volume 12, Issue 6 : 933-941.
10. Piscopo, G., and S. Haberman. (2011) "The Valuation of Guaranteed Lifelong Withdrawal Benefit Options in Variable Annuity Contracts and the Impact of Mortality Risk". *North American Actuarial Journal*, Volume 15, Issue 1 : 59-76.
11. Renshaw, A.E., and Haberman, S. (2006) "A cohort-based extension to the Lee-Carter model for mortality reduction factors". *Insurance:Mathematics and Economics*, Volume 38, Issue 3 : 556-570.
12. Wang, C.-W., and Yang, S.S. (2012) "Pricing Survivor Derivatives With Cohort Mortality Dependence Under The Lee-Carter Framework". *The Journal of Risk*, Volume 80, Issue 4 : 1027-1056.