

Introduction


Framework

Evaluation

Q&A

- 金管會要求金融業依照所需遵循的法規，訂定相對應的內規
- 金融業需遵守的外部法規超過5000部，內部規範則超過800部
- 內規條文制定的邏輯會以外規條文為基礎來編寫內規條文，所以條文與條文之間存在語意的相似性
- 因為外規變動內規也會跟著變動，所以建構AI關聯模型，進而建立外規與內規之間的關聯表

- 現有的AI關聯模型
 - ✓ 沒有辦法retrain
 - ✓ 客戶回饋BERT的結果不準



Introduction

Framework

Evaluation

Q&A

■ 目前有的資料

- ✓ 內規:6部共1623段
- ✓ 外規:6部共1226段
- ✓ 現有BERT產生的關聯表:4720組

→ 共有1,989,798組，其中1,985,078組不相關，4720組相關

Ex. 金融機構防制洗錢辦法

第 2 條

本辦法用詞定義如下：

一段

一、金融機構：包括下列之銀行業、證券期貨業、保險業及其他經金融監督管理委員會（以下簡稱本會）指定之金融機構：

（一）銀行業：包括銀行、信用合作社、辦理儲金匯兌之郵政機構、票券金融公司、信用卡公司及信託業。

（二）證券期貨業：包括證券商、證券投資信託事業、證券金融事業、證券投資顧問事業、證券集中保管事業、期貨商。

（三）保險業：包括保險公司、專業再保險公司及辦理簡易人壽保險業務之郵政機構。

A	B	C	D	E	F	G
內規部	內規條	內規段	外規部	外規條	外規段	相似度
5	3	2	832	21	2	0.873646379
5	3	2	834	16	11	0.872581124
5	3	3	834	15	12	0.968946517
5	3	3	833	9	6	0.940811276
5	3	3	832	19	11	0.938995957
5	3	3	835	7	6	0.93470329
5	4	1	831	9	3	0.883011222
5	4	1	834	13	23	0.834484875
5	4	2	835	5	3	0.959981382
5	4	2	833	7	3	0.959981382
5	4	2	835	6	4	0.911621213
5	4	2	834	14	4	0.911621213
5	4	2	833	8	4	0.911621213
5	4	2	832	18	3	0.911621213

Introduction

Framework

Evaluation

Q&A

- 實驗目標


- ✓ 輸入:一段外規
- ✓ 輸出:所有有相關的內規段落
 - 給定一段外規相關，可能輸出**多段**內規
 - 每一段外規輸出的內規段數並**不一致**

Introduction

Framework

Evaluation

Q&A




Introduction

Framework

Evaluation

Q&A




- 使用關聯表的4720組相似的內外規段+挑選4720組不相關的內外規段
- 將9440組資料分成train set和validation set
 - ✓ Train set (85%) : 4012組相關 + 4012組不相關，共8024組
 - ✓ Validation set (15%) : 708組相關 + 708組不相關，共1416組
 - validation set 不參與任何訓練，用於後面續練Bi-encoder時，監控validation loss才知道訓練幾輪要停止

Introduction

Framework

Evaluation

Q&A




- 從Train set的8024組資料中挑選1000筆資料 (根據BERT score標出的相關或不相關樣本，交大會人工挑選較確定的樣本，不採用隨機挑選的方式)，先初始訓練一個Bi-encoder
- Validation set的1416組資料中隨機挑選100筆資料當作驗證集
- 使用模型 : infloat / multilingual - e5 - large
- 損失函數 : BCE loss

Introduction

Framework

Evaluation

Q&A




- 使用1,989,798組內外規段

Introduction

Framework

Evaluation

Q&A




- 使用使用1,989,798組內外規段及訓練好的Bi-encoder，計算cosine similarity

Introduction

Framework

Evaluation

Q&A



- 使用使用1,989,798組內外規段計算BM25分數

Active Learning 挑選樣本策略

第一種方式：

- 將BM25分數和cosine similarity標準化到[0,1]，取分數差異較大的
 - 標準化後兩者的分布差異不一樣，導致會由cosine similarity決定
- 這種挑選樣本方法明顯不好，所以改嘗試以下三種方式

第二種方式：

- 不標準化BM25分數和cosine similarity，直接用rank差異較大的

第三種方式：

- 先根據BM25分數和cosine similarity判斷是否相似，取兩種結果不一致的

第四種方式：

- 取BM25分數和cosine similarity皆在threshold附近的

- 但嘗試不同的方法，便會需要挑選不同樣本，這樣可能會有重複人工標註的問題，所以希望可以在確定哪種效果比較好之前，先採用LLM標註的方式，以減少公司進行人工標註的人力
- 會先使用LLM(gemini-2.0-flash)取代公司人工標註，將LLM標註完的結果回去訓練Bi-encoder，看這三種方式哪一種較好，之後再採用那種方式來挑選樣本給公司進行人工標註

Active Learning 挑選樣本策略

- 以下為第二種方式(直接用兩者rank差異較大的)進行LLM標記的prompt：

```
11 prompt = f"""
12 你是一個專業的法規比對專家，請根據提供的兩段法規文本內容，判斷它們是否語義相似。
13
14 請注意：
15 1.  **相似 (labeled=1)**：如果兩段文本在表達相同或高度相關的法規概念、定義、條件、義務或行為時，即使措辭不同，也請判斷為相似。重點是表達的「意圖」和「核心法規含義」是否一致。
16 2.  **不相似 (labeled=0)**：如果兩段文本表達的法規概念、定義、條件、義務或行為完全不同，或即使有部分詞彙重疊，但核心法規含義不同，則請判斷為不相似。
17
18 請你對以下這組法規文本進行判斷：
19
20 內部法規文本 (Internal_Content):
21 \"\"\"{internal_content}\"\"\"
22
23 外部法規文本 (External_Content):
24 \"\"\"{external_content}\"\"\"
25
26 請你以 JSON 格式輸出你的判斷結果，包含以下兩個欄位：
27 - "LLM_labeled": 你的判斷 (1 代表相似，0 代表不相似)
28 - "reason": 簡要說明你判斷相似或不相似的理由。

30 範例輸出：
31 {{
32     "LLM_labeled": 1,
33     "reason": "兩段文本都提到了對客戶身份的確認以及相關紀錄的保存，核心概念一致。"
34 }}
35
36 或
37
38 {{
39     "LLM_labeled": 0,
40     "reason": "兩段文本提及的法規標的和行為完全不同，一個是資恐通報，另一個是內部訓練規定。"
41 }}
42 """
```

Active Learning 挑選樣本策略

- 以下為第二種方式(直接用兩者rank差異較大的) LLM標記標記結果範例：

```
{
  "Internal_Content": "1.我國政府機關.",
  "Internal_部ID": "10",
  "Internal_條ID": "4",
  "Internal_段ID": "47",
  "External_Content": "四、查獲故意隱匿重大違規事項不予揭露者,應由權責單位適當處理.",
  "External_部ID": "834",
  "External_條ID": "15",
  "External_段ID": "10",
  "BM25_Similarity": 0.0,
  "Cosine_Similarity": -0.4021623730659485,
  "BM25_Percentile": 0.0,
  "Cosine_Percentile": 31.25,
  "Percentile Disagreement": 31.25,
  "LLM_labeled": 0,
  "LLM_reason": "第一段文本提及的是政府機關，第二段文本提及的是查獲隱匿違規事項的處理。兩者法規標的和內容完全不同，因此判斷為不相似。"
},
```

LLM的輸出結果

Introduction

Framework

Evaluation

Q&A

- 因公司無法人工確認所有樣本(接近兩百萬組)是否相關
 - ✓ 希望可以改用LLM標註以減少人力，但需要先確認LLM標註的效果
- 目前只有BERT輸出的關聯表能當作參考，所以先使用LLM進行標註這些被認為是關聯的內外規組
 - ✓ 可以先觀察LLM標記的效果好不好
 - ✓ 若LLM標記效果好的話，則P11~14 active learning的標註則可以使用LLM取代人工標註

請輸入內部法規文本 (Internal_Content):

一、應確認客戶身分並留存相關紀錄憑證。

請輸入外部法規文本 (External_Content):

第5條金融機構確認客戶身分措施,應包括對客戶身分之持續審查,並依下列規定辦理:

正在呼叫 Gemini API 進行判斷...

--- 判斷結果 ---

LLM_labeled: 1 (相似)

Reason: 內部法規文本要求確認客戶身分並留存紀錄，外部法規文本雖更廣泛，但包含了對客戶身分的確認，因此在核心意涵上是相似的。

LLM的標記結果