

法規條文關聯

分析債券、財報資訊

Introduction

Framework


Evaluation

Q&A

- 金管會要求金融業依照所需遵循的法規，訂定相對應的內規
- 金融業需遵守的外部法規超過5000部，內部規範則超過800部
- 內規條文制定的邏輯會以外規條文為基礎來編寫內規條文，所以條文與條文之間存在語意的相似性
- 因為外規變動內規也會跟著變動，所以建構AI關聯模型，進而建立外規與內規之間的關聯表

■ 現有的AI關聯模型

- ✓ 沒有辦法retrain
- ✓ BERT的結果有改善空間



Introduction

Framework

Evaluation

Q&A

■ 目前有的資料

- ✓ 內規:6部共1623段
- ✓ 外規:6部共1226段
- ✓ 現有BERT產生的關聯表:4720組

→ 共有1,989,798組，其中1,985,078組不相關，4720組相關

Ex. 金融機構防制洗錢辦法

第 2 條

本辦法用詞定義如下：

一段

一、金融機構：包括下列之銀行業、證券期貨業、保險業及其他經金融監督管理委員會（以下簡稱本會）指定之金融機構：

（一）銀行業：包括銀行、信用合作社、辦理儲金匯兌之郵政機構、票券金融公司、信用卡公司及信託業。

（二）證券期貨業：包括證券商、證券投資信託事業、證券金融事業、證券投資顧問事業、證券集中保管事業、期貨商。

（三）保險業：包括保險公司、專業再保險公司及辦理簡易人壽保險業務之郵政機構。

A	B	C	D	E	F	G
內規部	內規條	內規段	外規部	外規條	外規段	相似度
5	3	2	832	21	2	0.873646379
5	3	2	834	16	11	0.872581124
5	3	3	834	15	12	0.968946517
5	3	3	833	9	6	0.940811276
5	3	3	832	19	11	0.938995957
5	3	3	835	7	6	0.93470329
5	4	1	831	9	3	0.883011222
5	4	1	834	13	23	0.834484875
5	4	2	835	5	3	0.959981382
5	4	2	833	7	3	0.959981382
5	4	2	835	6	4	0.911621213
5	4	2	834	14	4	0.911621213
5	4	2	833	8	4	0.911621213
5	4	2	832	18	3	0.911621213

Introduction

Framework

Evaluation

Q&A

- 實驗目標

- ✓ 輸入:一段外規

- ✓ 輸出:所有有相關的內規段落

- 給定一段外規相關，可能輸出**多段**內規


- 每一段外規輸出的內規段數並**不一致**

Introduction

Framework

Evaluation

Q&A




Introduction

Framework

Evaluation

Q&A




- 使用關聯表的4720組相似的內外規段+挑選4720組不相關的內外規段
- 將9440組資料分成train set和validation set
 - ✓ Train set (85%) : 4012組相關 + 4012組不相關, 共8024組
 - ✓ Validation set (15%) : 708組相關 + 708組不相關, 共1416組
 - validation set 不參與任何訓練, 用於後面續練Bi-encoder時, 監控validation loss才知道訓練幾輪要停止

Introduction

Framework

Evaluation

Q&A



- 從Train set的8024組資料中挑選1000筆資料 (根據BERT score標出的相關或不相關樣本，交大會人工挑選較確定的樣本，不採用隨機挑選的方式)，先初始訓練一個Bi-encoder
- Validation set的1416組資料中隨機挑選100筆資料當作驗證集
- 使用模型：infloat / multilingual - e5 - large
- 損失函數：MultipleNegativesRankingLoss
 - 只需要用到正樣本進行訓練，會從正樣本中自動生成的 In-batch Negatives
- 損失函數：ContrastiveLoss

■ MultipleNegativesRankingLoss

- 核心思想是利用In-Batch Negatives來進行訓練
- 假設: 在一個批次中，對於每個query，只有一個正相關的document。批次中所有其他query所對應的document都被視為當前query的負相關例子
- 假設一個訓練批次大小為 N ，包含 N 個查詢 $Q_1, Q_2, \dots, Q_N$ 和 N 個對應的文件 $D_1, D_2, \dots, D_N$ ，對於 Q_i 而言，正例是 D_i ，負例則是 D_j ($i \neq j$)
- 目標是最大化正例對的相似度，同時最小化正例與其對應負例的相似度
- 無需手動構建負例，簡化了數據準備流程
- 缺點是一個 Query 最多只能有一個正例

■ ContrastiveLoss


- 要求相似的樣本在嵌入空間中距離較近，而那些不相似的樣本則至少要相距一定的margin
- $L(y, D) = y \cdot D^2 + (1 - y) \cdot \max(0, m - D)^2$
- $y=1$ 時，損失為 D^2 ，鼓勵模型將正例對的距離 D 拉近。距離越近，損失越小
- $y=0$ 時，損失為 $\max(0, m - D)^2$ ，如果負例對的距離 $D \geq m$ (已經足夠遠)，損失為 0，表示模型已經成功將這些不相似的樣本推開到足夠的距離，不再需要懲罰
- $y=0$ 時，損失為 $\max(0, m - D)^2$ ，如果負例對的距離 $D < m$ (距離太近)：損失為 $(m - D)^2$ ，表示模型需要被懲罰，鼓勵將這些不相似的樣本進一步推開，直到它們之間的距離達到或超過 margin

Introduction

Framework

Evaluation

Q&A



樣本預測結果：

Query: 八、保險業應於人壽保險、投資型保險及年金保險契約之保險受益人確定或經指定時，採取下列措施：（一）對於經指定為保險受益人者，應取得其姓名或名稱及身分證明文件號碼或註冊設立日期。

Doc: 八、辦理保險經紀業務時，應於洽訂人壽保險、投資型保險及年金保險契約之保險受益人確定或經指定時，採取下列措施：（一）對於經指定為保險受益人者，應取得其姓名或名稱及身分證明文件號碼或註冊設立日期。

原始標籤: 1, 預測相似度: 0.9747

Query: 一項第一款之物者，其所有人、管領人或持有人得向海關申請提供足額之保證金，准予撤銷扣留後發還之。

Doc: 五、測試資料輸出正確及完整。

原始標籤: 0, 預測相似度: 0.4821

Query: (一)客戶來自未採取有效防制洗錢或打擊資恐之高風險地區或國家，包括但不限於主管機關函轉國際防制洗錢組織所公告防制洗錢與打擊資恐有嚴重缺失之國家或地區，及其他未遵循或未充分遵循國際防制洗錢組織建議之國家或地區。

Doc: 6、發現疑似洗錢或資恐交易時，或有自本行定義之洗錢或資恐高風險國家或地區存入款項之交易時。

原始標籤: 1, 預測相似度: 0.6739

Query: 二、協調督導全面性洗錢及資恐風險辨識及評估之執行。

Doc: 二、全面性洗錢及資恐風險評估方法論及差異情形。

原始標籤: 1, 預測相似度: 0.8343

Query: 四、由專責單位簽報專責主管核定後，立即向法務部調查局申報。

Doc: 4. 建立業務關係時查有客戶列警示戶或衍生管制帳戶或其他同業拒絕往來客戶之紀錄。

原始標籤: 0, 預測相似度: 0.5129


■ 損失函數: MultipleNegativesRankingLoss

Introduction

Framework

Evaluation

Q&A



樣本預測結果：

Query: 拾、證券商對達一定金額以上之通貨交易，應依下列規定辦理：

Doc: 第十二條（一定金額以上之通貨交易申報程序）本公司對達一定金額以上之通貨交易，應依下列規定辦理：

原始標籤：1，預測相似度：0.9302

Query: (二)足資懷疑該客戶或交易涉及洗錢或資恐。

Doc: (二)足資懷疑該客戶或交易涉及洗錢或資恐。

原始標籤：1，預測相似度：0.9945

Query: 3保險業應將人壽保險契約之受益人納為是否執行強化確認客戶身分措施之考量因素。人壽保險契約之保險受益人為法人或信託之受託人，經評估屬較高風險者，應採取強化確認客戶身分措施，包括於給付保險金前，採取合理措施辨識及驗證實質受益人身分。

Doc: 七、疑似洗錢或資恐交易申報及資恐防制法指定對象之財物或財產上利益及其所在地之通報。

原始標籤：0，預測相似度：0.4602

Query: 1前項第一款洗錢及資恐風險之辨識、評估及管理，應至少涵蓋客戶、地域、產品及服務、交易或支付管道等面向，並依下列規定辦理：

Doc: 一、就洗錢及資恐風險進行辨識、評估、管理之相關政策及程序。

原始標籤：1，預測相似度：0.8632

Query: 4文件資料無法進行查證。

Doc: (五)資料輸出。

原始標籤：0，預測相似度：0.5420


■ 損失函數：ContrastiveLoss

Introduction

Framework

Evaluation

Q&A




- 使用1,989,798組內外規段

Introduction

Framework

Evaluation

Q&A




- 使用使用1,989,798組內外規段及訓練好的Bi-encoder，計算cosine similarity

Introduction

Framework

Evaluation

Q&A



- 使用使用1,989,798組內外規段計算BM25分數

Active Learning 挑選樣本策略

第一種方式：

- 將BM25分數和cosine similarity標準化到[0,1]，取分數差異較大的
 - 標準化後兩者的分布差異不一樣，導致會由cosine similarity決定

→ 這種挑選樣本方法明顯不好，所以改嘗試以下三種方式

第二種方式：

- 不標準化BM25分數和cosine similarity，直接用rank差異較大的

第三種方式：

- 先根據BM25分數和cosine similarity判斷是否相似，取兩種結果不一致的

第四種方式：

- 取BM25分數和cosine similarity皆在threshold附近的

- 但嘗試不同的方法，便會需要挑選不同樣本，這樣可能會有重複人工標註的問題，所以希望可以在確定哪種效果比較好之前，先採用LLM標註的方式，以減少公司進行人工標註的人力
- 會先使用LLM(gemini-2.0-flash)取代公司人工標註，將LLM標註完的結果回去訓練Bi-encoder，看這三種方式哪一種較好，之後再採用那種方式來挑選樣本給公司進行人工標註

Active Learning 挑選樣本策略

- 以下為第二種方式(直接用兩者rank差異較大的)進行LLM標記的prompt：

```
11 prompt = f"""
12 你是一個專業的法規比對專家，請根據提供的兩段法規文本內容，判斷它們是否語義相似。
13
14 請注意：
15 1.  **相似 (labeled=1)**：如果兩段文本在表達相同或高度相關的法規概念、定義、條件、義務或行為時，即使措辭不同，也請判斷為相似。重點是表達的「意圖」和「核心法規含義」是否一致。
16 2.  **不相似 (labeled=0)**：如果兩段文本表達的法規概念、定義、條件、義務或行為完全不同，或即使有部分詞彙重疊，但核心法規含義不同，則請判斷為不相似。
17
18 請你對以下這組法規文本進行判斷：
19
20 內部法規文本 (Internal_Content):
21 \"\"\"{internal_content}\"\"\"
22
23 外部法規文本 (External_Content):
24 \"\"\"{external_content}\"\"\"
25
26 請你以 JSON 格式輸出你的判斷結果，包含以下兩個欄位：
27 - "LLM_labeled": 你的判斷 (1 代表相似，0 代表不相似)
28 - "reason": 簡要說明你判斷相似或不相似的理由。

30 範例輸出：
31 {{
32     "LLM_labeled": 1,
33     "reason": "兩段文本都提到了對客戶身份的確認以及相關紀錄的保存，核心概念一致。"
34 }}
35
36 或
37
38 {{
39     "LLM_labeled": 0,
40     "reason": "兩段文本提及的法規標的和行為完全不同，一個是資恐通報，另一個是內部訓練規定。"
41 }}
42 """
```


Active Learning 挑選樣本策略

- 以下為第二種方式(直接用兩者rank差異較大的) LLM標記標記結果範例：

```
{
  "Internal_Content": "1.我國政府機關.",
  "Internal_部ID": "10",
  "Internal_條ID": "4",
  "Internal_段ID": "47",
  "External_Content": "四、查獲故意隱匿重大違規事項不予揭露者,應由權責單位適當處理.",
  "External_部ID": "834",
  "External_條ID": "15",
  "External_段ID": "10",
  "BM25_Similarity": 0.0,
  "Cosine_Similarity": -0.4021623730659485,
  "BM25_Percentile": 0.0,
  "Cosine_Percentile": 31.25,
  "Percentile Disagreement": 31.25,
  "LLM_labeled": 0,
  "LLM_reason": "第一段文本提及的是政府機關，第二段文本提及的是查獲隱匿違規事項的處理。兩者法規標的和內容完全不同，因此判斷為不相似。"
},
```

LLM的輸出結果

Introduction

Framework

Evaluation

Q&A

- 因公司無法人工確認所有樣本(接近兩百萬組)是否相關
 - ✓ 希望可以改用LLM標註以減少人力，但需要先確認LLM標註的效果
- 目前只有BERT輸出的關聯表能當作參考，所以先使用LLM進行標註這些被認為是關聯的內外規組
 - ✓ 可以先觀察LLM標記的效果好不好
 - ✓ 若LLM標記效果好的話，則P15~17 active learning的標註則可以使用LLM取代人工標註

請輸入內部法規文本 (Internal_Content):

一、應確認客戶身分並留存相關紀錄憑證。

請輸入外部法規文本 (External_Content):

第5條金融機構確認客戶身分措施,應包括對客戶身分之持續審查,並依下列規定辦理:

正在呼叫 Gemini API 進行判斷...

--- 判斷結果 ---

LLM_labeled: 1 (相似)

Reason: 內部法規文本要求確認客戶身分並留存紀錄，外部法規文本雖更廣泛，但包含了對客戶身分的確認，因此在核心意涵上是相似的。

LLM的標記結果

法規條文關聯

分析債券、財報資訊

資料

- 債券說明書11003份
 - 共1954間公司，其中有859間公司提到會進行併購
- 財報(10-K)：從SEC網站下載1954間公司的所有財報

目標

- 找出哪些公司實際有進行併購但債券說明書沒提到會進行併購
或
- 找出債券說明書提到會進行併購但實際沒進行併購

步驟1：確認債券發行目的

- 先從債券說明書中找到use of proceeds的段落

USE OF PROCEEDS

The net proceeds to AT&T from the sale of the Debentures are estimated to be \$291.9 million and are expected to be applied towards refunding commercial paper and general corporate purposes.

- 透過語言模型(gemini-1.5-flash)標記出債券發行目的

```
prompt = (  
    "以下是公司發行債券的十種用途，請根據參考資料判斷公司是否包含這些用途。\\n"  
    "請按照以下格式回答：\\n"  
    "[1, 0, 1, 0, 0, 1, 0, 0, 1, 0] (1 表示包含, 0 表示不包含，順序對應下列用途)\\n"  
    "請只提供回答清單，不要提供任何額外解釋或敘述\\n\\n"  
    "如果無法根據提供的參考資料判斷，請回答[0, 0, 0, 0, 0, 0, 0, 0, 0, 0]"  
    "用途：\\n"  
    "1. 償還現有債務\\n"  
    "2. 資本支出\\n"  
    "3. 收購\\n"  
    "4. 庫藏股回購\\n"  
    "5. 營運資金\\n"  
    "6. 償還商業票據\\n"  
    "7. 一般公司用途\\n"  
    "8. 短期投資\\n"  
    "9. 提高財務槓桿\\n"  
    "10. 交換性質\\n\\n"  
    "參考資料如下：\\n"  
)
```

H	I	J	K	L	M	N	O	P	Q	R	S
Filename	acted Cor	repay indebtedness	capital expenditure	acquisition	repurchase common stock	working capital	repay commercial paper	general corporate purpose	short-term investment	increase financial leverage	exchange offer
95_1581_5907_424B2_17.txt	The net pr	1	1	1	1	0	1	1	0	0	0

步驟2：從財報(Item7)確認公司是否真的進行併購

- 將財報分段後，使用語言模型(Gemini-2.0-flash)找出公司是否真的進行併購
- 下圖為財報範例

```
{  
  "Section": "ITEM 7.",
```

```
  "Content": "MANAGEMENT'S NARRATIVE ANALYSIS OF RESULTS OF OPERATIONS The following discussion relates to Apache Corporation (Apache or the Company) and its consolidated subsidiaries and should be read together in conjunction with the Company's Consolidated Financial Statements and accompanying notes included in Part IV, Item 15 of this Annual Report on Form 10-K, and the risk factors and related information set forth in Part I, Item 1A and Part II, Item 7A of this Annual Report on Form 10-K. This section of this Annual Report on Form 10-K generally discusses 2022 and 2021 items and year-to-year comparisons between 2022 and 2021. Discussions of 2020 items and year-to-year comparisons between 2021 and 2020 that are not included in this Annual Report on Form 10-K are incorporated by reference to Management's Narrative Analysis of Results of Operations in Part II, Item 7 of Apache Corporation's Annual Report on Form 10-K for the fiscal year ended December 31, 2021 (filed with the SEC on February 22, 2022). On March 1, 2021, Apache consummated a holding company reorganization (the Holding Company Reorganization), pursuant to which Apache became a direct, wholly owned subsidiary of APA Corporation (APA), and all of the Company's outstanding shares automatically converted into equivalent corresponding shares of APA. Pursuant to the Holding Company Reorganization, APA became the successor issuer to the Company pursuant to Rule 12g-3(a) under the Exchange Act and replaced the Company as the public company trading on the Nasdaq Global Select Market under the ticker symbol APA. The Holding Company Reorganization modernized APA's operating and legal structure, making it more consistent with other companies that have affiliates operating around the globe. Refer to Note 2 Transactions with Parent Affiliate in the Notes to Consolidated Financial Statements set forth in Part IV, Item 15 of this Annual Report on Form 10-K for more detail. Overview Apache, a direct, wholly owned subsidiary of APA, is an independent energy company that explores for, develops, and produces natural gas, crude oil, and natural gas liquids (NGLs). The Company's upstream business currently has exploration and production operations in three geographic areas: the U.S., Egypt, and offshore the U.K. in the North Sea (North Sea). Prior to the BCP Business Combination defined below, the Company's midstream business was operated by Altus. Altus owned, developed, and operated a midstream energy asset network in the Permian Basin of West Texas. Apache believes energy underpins global progress, and the Company wants to be a part of the conversation and solution as society works to meet growing global demand for reliable and affordable energy. Apache strives to meet those challenges while creating value for all its stakeholders. Early in 2020, impacts of the coronavirus disease 2019 (COVID-19) pandemic and related governmental actions began to exert significant downward pressure on crude oil and natural gas prices. Since that time, commodity prices worldwide have largely rebounded; however, uncertainties in the global supply chain, commodity prices, and financial markets, including the impact of inflation, rising interest rates, and the conflict in Ukraine continue to impact oil supply and demand. Despite these
```

步驟2：從財報(Item7)確認公司是否真的進行併購

● 標記結果範例

```
"cik": "320193",
"1996": "- 沒有提及收購",
"1997": "- 收購對象: NeXT\n交易時間: 1997 年 2 月\n收購金額: 427 百萬美元\n支付方式: 未提及\n描述目的或背景: NeXT 開發、行銷和支援軟體，使客戶能夠在 Internet/World Wide Web、內部網路和企業範圍的客戶端/伺服器網路上實施業務應用程式。",
"1998": "- 沒有提及收購 (除了完成 1997 年的 PCC 資產收購)",
"1999": "- 沒有提及收購",
"2000": "- 沒有提及收購",
"2001": "- 收購對象: PowerSchool, Inc.\n交易時間: 2001 年 5 月\n收購金額: $66.1 million (總購買價格)\n支付方式: 未提及，推測為現金\n描述目的或背景: PowerSchool 提供 K-12 學校的網路學生資訊系統。",
"2002": "- 收購對象: Emagic GmbH\n交易時間: 第四季 (約為 2002 年 7 月至 9 月)\n收購金額: 約 $30 million (現金)\n支付方式: 現金\n描述目的或背景: Emagic 提供專業的電腦音樂製作軟體解決方案",
"2003": "沒有提及收購",
"2004": "- 收購對象: Emagic GmbH\n交易時間: 2002年(財報提及)\n收購金額: 約 3000 萬美元\n支付方式: 現金\n描述目的或背景: Emagic GmbH 為電腦音樂製作的專業軟體解決方案供應商。",
"2005": "- 沒有提及收購",
"2006": "- 沒有提及收購",
"2007": "- 沒有提及收購",
"2008": "- 沒有提及收購",
"2009": "- 沒有提及收購",
"2010": "- 在2010年財報中，提到「...payments made in connection with business acquisitions, net of cash acquired, of $638 million.」\n但沒有進一步描述是收購了哪間公司、部門或品牌，也無法判斷收購時間與支付方式。",
"2011": "- 在2011年財報中，提到「...payments made in connection with business acquisitions, net of cash acquired, of $244 million.」\n但沒有進一步描述是收購了哪間公司、部門或品牌，也無法判斷收購時間與支付方式。",
"2012": "- 沒有提及收購",
"2013": "- 沒有提及收購",
"2014": "- 收購對象: Beats Music, LLC (提供訂閱串流音樂服務)\n交易時間: 2014年 (未提供具體月份或季度)\n描述目的或背景: 拓展音樂服務\n- 收購對象: Beats Electronics, LLC (生產Beats耳機、喇叭與音訊軟體)\n交易時間: 2014年 (未提供具體月份或季度)\n描述目的或背景:",
"2015": "- 沒有提及收購",
"2016": "- 沒有提及收購",
"2017": "- 沒有提及收購",
"2018": "- 沒有提及收購",
"2019": "- 沒有提及收購",
"2020": "- 收購對象: 未明確提及，但提及有「cash paid for business acquisitions, net of cash acquired, of $1.5 billion」\n交易時間: 2020年\n收購金額: 15億美元\n支付方式: 現金\n描述目的或背景: 未提及",
"2021": "- 沒有提及收購",
"2022": "- 沒有提及收購",
"2023": "- 沒有提及收購"
```

蘋果公司併購&發債時間軸

發行2001年到期的債券，
未詳細說明發行目的

完成了對 PCC 部分資產的收購

收購了 NeXT

1997/8

約3,000萬美元現金收購了Emagic GmbH

2001/5

收購 PowerSchool, Inc.

同意收購 Mac OS 作業系統的授權經銷商 Power Computing Corporation (PCC) 的部分資產，包括 PCC 的客戶資料庫及其 Mac OS 分銷許可證

發行四檔債券，分別於
2016,2018,2023,2024年
到期，皆提到會進行併購

發行四檔債券，分別於
2020,2022,2025,2045年
到期，皆提到會進行併購

2014年

發行七檔債券，分別於
2018,2019,2021,2023,2026,
2036,2046年到期，皆提到會
進行併購

2015/5/6

發行五檔債券，分別於
2017,2020,2022,2025,
2045年到期，皆提到會
進行併購

發行六檔債券，分別於
2019,2020,2022,2024,2027,
2047年到期，皆提到會進行
併購

2016/7/28

發行四檔債券，分別於
2019,2021,2026,2046
年到期，皆提到會進行
併購

2017/2/14

發行一檔債券，於2047
年到期，提到會進行併
購

發行五檔債券，分別於
2017,2019,2021,2024,
2044年到期，皆提到會
進行併購

該公司完成了多項業務收購，包括收購提供訂閱串流音樂服務的 Beats Music, LLC 和生產 Beats 耳機、揚聲器和音訊軟體的 Beats Electronics, LLC

1996年 1997/2 1998/1/28 2002 年 2013 年 2015/2/2 2016/2/16 2017/2/2

蘋果公司併購&發債時間軸

